



UNIVERSITÀ DEGLI STUDI DI SALERNO

Dipartimento di Informatica

**Corso di Laurea Magistrale in Informatica**

*Corso di Strumenti Formali per la Bioinformatica*



**Autori:**

Marco Brescia Mat. NF22500154

Manuel Cieri Mat. NF22500033

Federica Graziuso Mat. NF22500245

**Repository GitHub:**

[github.com/FLaTNNBio/CATE-LLaM](https://github.com/FLaTNNBio/CATE-LLaM)

---

**ANNO ACCADEMICO 2025/2026**

---

# INDICE

|          |                                                                       |          |
|----------|-----------------------------------------------------------------------|----------|
| <b>1</b> | <b>Introduzione</b>                                                   | <b>1</b> |
| 1.1      | Obiettivo del lavoro . . . . .                                        | 1        |
| 1.2      | CATE, RCT e dati osservazionali: nozioni . . . . .                    | 2        |
| 1.2.1    | Effetto causale medio ed effetto causale condizionato . . . . .       | 2        |
| 1.2.2    | Trial randomizzati e identificazione causale . . . . .                | 2        |
| 1.2.3    | Dati osservazionali e principali difficoltà . . . . .                 | 3        |
| 1.2.4    | Rilevanza del problema nel presente lavoro . . . . .                  | 3        |
| 1.3      | Struttura del documento . . . . .                                     | 4        |
| <b>2</b> | <b>Analisi Dataset</b>                                                | <b>5</b> |
| 2.1      | Introduzione . . . . .                                                | 5        |
| 2.2      | Dataset MIMIC-IV . . . . .                                            | 6        |
| 2.2.1    | Scenari Clinici e Coorti Estratte . . . . .                           | 7        |
| 2.3      | Pipeline di Costruzione del Dataset . . . . .                         | 9        |
| 2.3.1    | Definizione del tempo zero . . . . .                                  | 9        |
| 2.3.2    | Definizione del trattamento (T) . . . . .                             | 9        |
| 2.3.3    | Definizione dell’outcome (Y) . . . . .                                | 9        |
| 2.3.4    | Finestre di estrazione delle covariate (Baseline e History) . . . . . | 10       |
| 2.3.5    | Criteri di inclusione ed esclusione . . . . .                         | 10       |
| 2.3.6    | Costruzione delle covariate baseline . . . . .                        | 10       |
| 2.3.7    | Cleaning e preprocessing . . . . .                                    | 11       |

|          |                                                                                                |           |
|----------|------------------------------------------------------------------------------------------------|-----------|
| 2.4      | Metodologia di Analisi e Validazione Causale . . . . .                                         | 11        |
| 2.4.1    | Stima del Propensity Score e Ponderazione . . . . .                                            | 12        |
| 2.4.2    | Valutazione del Bilanciamento . . . . .                                                        | 12        |
| 2.4.3    | Stima dell'Effetto Causale (DR-Learner) . . . . .                                              | 13        |
| 2.4.4    | Policy Learning ed Eterogeneità . . . . .                                                      | 13        |
| 2.4.5    | Policy Learning e Regole Decisionali . . . . .                                                 | 13        |
| 2.5      | Risultati Sperimentali e Analisi in MIMIC-IV . . . . .                                         | 14        |
| 2.5.1    | Uso Precoce di Vasopressori in Terapia Intensiva ( <code>vaso_v0</code> ) . . . . .            | 14        |
| 2.5.2    | Trasfusioni di Globuli Rossi (RBC) in Pazienti Critici ( <code>rbc_v1_fixed</code> ) . . . . . | 15        |
| 2.5.3    | Corticosteroidi nella Sepsì ( <code>sepsis_v2</code> ) . . . . .                               | 16        |
| 2.5.4    | Analisi del Propensity Score e Bilanciamento . . . . .                                         | 17        |
| 2.5.5    | Somministrazione Precoce di Diuretici nella Sepsì ( <code>diur_v1</code> ) . . . . .           | 19        |
| 2.6      | AIDS Clinical Trials Group (ACTG 175) . . . . .                                                | 23        |
| 2.6.1    | Validazione su Dataset RCT . . . . .                                                           | 23        |
| 2.6.2    | Confronto Modelli: DR-Learner vs. BCAUSS . . . . .                                             | 25        |
| 2.6.3    | Conclusione Operativa e Sintesi Critica . . . . .                                              | 26        |
| <b>3</b> | <b>Bias Tools</b>                                                                              | <b>27</b> |
| 3.1      | Bias Tools: Introduzione . . . . .                                                             | 27        |
| 3.2      | Selection Bias Tool . . . . .                                                                  | 28        |
| 3.2.1    | Definizione del problema . . . . .                                                             | 28        |
| 3.2.2    | Scelte metodologiche della soluzione . . . . .                                                 | 29        |
| 3.2.3    | Implementazione del tool . . . . .                                                             | 31        |
| 3.3      | Confounding Bias Tool . . . . .                                                                | 34        |
| 3.3.1    | Definizione del problema . . . . .                                                             | 34        |
| 3.3.2    | Scelte metodologiche della soluzione . . . . .                                                 | 34        |
| 3.3.3    | Implementazione del tool . . . . .                                                             | 37        |
| 3.4      | Cleaning e Dataset Harmonization . . . . .                                                     | 40        |
| 3.4.1    | Motivazione del passaggio di cleaning . . . . .                                                | 40        |
| 3.4.2    | Metodologia della soluzione . . . . .                                                          | 40        |
| 3.4.3    | Implementazione del tool di armonizzazione . . . . .                                           | 42        |
| 3.5      | Risultati ottenuti . . . . .                                                                   | 44        |
| 3.5.1    | Contesto sperimentale: dataset ACTG175 . . . . .                                               | 45        |

|          |                                                               |           |
|----------|---------------------------------------------------------------|-----------|
| 3.5.2    | Risultati del Selection Bias Tool . . . . .                   | 45        |
| 3.5.3    | Risultati del Confounding Bias Tool . . . . .                 | 48        |
| 3.5.4    | Risultati finali . . . . .                                    | 51        |
| <b>4</b> | <b>LLM Prediction</b>                                         | <b>58</b> |
| 4.1      | Large Language Models . . . . .                               | 58        |
| 4.1.1    | Descrizione del dataset . . . . .                             | 58        |
| 4.1.2    | Obiettivo del lavoro . . . . .                                | 59        |
| 4.1.3    | Architettura del sistema e progettazione dei prompt . . . . . | 59        |
| 4.2      | Analisi dei comportamenti dei modelli . . . . .               | 60        |
| 4.3      | Confronto tra BCAUSS e LLM nella stima del CATE . . . . .     | 62        |
| 4.3.1    | Dominio RCT . . . . .                                         | 62        |
| 4.3.2    | Dominio OBS . . . . .                                         | 63        |
| 4.3.3    | Analisi visiva . . . . .                                      | 64        |
| 4.3.4    | Analisi della concordanza tramite Bland–Altman . . . . .      | 65        |
| 4.3.5    | Metriche di errore tra BCAUSS e modelli LLM . . . . .         | 67        |
| 4.3.6    | Correlazione lineare e di rango . . . . .                     | 69        |
| 4.4      | Analisi complessiva e conclusioni . . . . .                   | 70        |

---

---

# CAPITOLO 1

---

## INTRODUZIONE

### 1.1 Obiettivo del lavoro

L'obiettivo di questo lavoro è analizzare il problema della stima del *Conditional Average Treatment Effect* (CATE) in ambito clinico, con particolare attenzione alla capacità dei modelli linguistici di cogliere l'eterogeneità individuale della risposta al trattamento. In molti contesti applicativi, infatti, non è sufficiente stabilire se un trattamento sia mediamente efficace sull'intera popolazione, ma è necessario comprendere se il suo effetto vari in funzione delle caratteristiche del singolo paziente.

L'idea di fondo è partire da un dataset derivato da uno studio randomizzato, assunto come riferimento iniziale, e trasformarlo in una versione pseudo-osservazionale mediante l'introduzione controllata di fonti di distorsione tipiche dei dati clinici non randomizzati. Questo consente di costruire un ambiente sperimentale in cui valutare come cambia la stima del CATE quando vengono meno le condizioni ideali garantite dalla randomizzazione.

Su questa base, il lavoro persegue due obiettivi principali. Il primo è valutare in che misura i *Large Language Models* possano essere impiegati come strumenti per la predizione del CATE, analizzandone la capacità di restituire stime informative, sensibili alle differenze individuali e compatibili con un problema di inferenza causale. Il secondo obiettivo è verificare se, in presenza di bias artificialmente introdotti, i modelli linguistici siano in grado di produrre stime del CATE coerenti con quelle ottenute nel dominio iniziale, mostrando quindi una qualche capacità di adattarsi al cambiamento di distribuzione dei dati e di non essere eccessivamente guidati dalle distorsioni introdotte.

Più in generale, il lavoro intende contribuire alla comprensione dei limiti e delle potenzialità degli LLM in un compito che richiede non solo capacità predittiva, ma anche coerenza rispetto alla struttura causale dei dati. L'attenzione non è quindi rivolta esclusivamente alla qualità numerica delle predizioni, ma anche alla loro stabilità, interpretabilità e sensibilità alla presenza di bias, elementi fondamentali in applicazioni ad alto impatto come quelle cliniche.

## 1.2 CATE, RCT e dati osservazionali: nozioni

Per comprendere il contesto di questo lavoro è necessario richiamare alcune nozioni fondamentali dell'inferenza causale. In ambito clinico, il problema centrale non consiste soltanto nel descrivere associazioni tra variabili, ma nel determinare se un trattamento produca realmente un effetto su un outcome di interesse e, soprattutto, se tale effetto vari da paziente a paziente. In questa prospettiva, il concetto di eterogeneità dell'effetto del trattamento assume un ruolo centrale.

### 1.2.1 Effetto causale medio ed effetto causale condizionato

Sia  $T \in \{0, 1\}$  una variabile di trattamento binaria, dove  $T = 1$  indica la presenza del trattamento e  $T = 0$  la sua assenza. Indichiamo inoltre con  $Y(1)$  e  $Y(0)$  i due *potential outcomes*, cioè gli outcome che lo stesso individuo manifesterebbe rispettivamente sotto trattamento e sotto controllo. In questo formalismo, l'effetto causale individuale è definito come:

$$Y(1) - Y(0).$$

Tale quantità, tuttavia, non è direttamente osservabile, poiché per ciascun individuo è possibile osservare solo uno dei due outcome potenziali. Questo costituisce il problema fondamentale dell'inferenza causale.

A livello di popolazione, una quantità di interesse è l'*Average Treatment Effect* (ATE), definito come:

$$ATE = \mathbb{E}[Y(1) - Y(0)].$$

L'ATE misura quindi l'effetto medio del trattamento sull'intera popolazione studiata.

Nel presente lavoro, tuttavia, l'attenzione è rivolta soprattutto al *Conditional Average Treatment Effect* (CATE), definito come:

$$\tau(x) = \mathbb{E}[Y(1) - Y(0) \mid X = x],$$

dove  $X$  rappresenta il vettore delle covariate pre-trattamento del paziente. Il CATE descrive l'effetto medio del trattamento condizionato a un determinato profilo clinico, e consente quindi di studiare l'eterogeneità della risposta terapeutica. In termini applicativi, questa quantità è particolarmente rilevante perché permette di distinguere sottogruppi di pazienti che potrebbero beneficiare maggiormente, meno, o addirittura essere danneggiati dallo stesso intervento.

### 1.2.2 Trial randomizzati e identificazione causale

Il contesto ideale per la stima degli effetti causali è rappresentato dai *Randomized Controlled Trials* (RCT). In un trial randomizzato, infatti, l'assegnazione del trattamento avviene in modo casuale, così che il trattamento risulti indipendente dalle covariate baseline del paziente. In forma compatta, questa proprietà può essere espressa come:

$$P(T = 1 \mid X) = P(T = 1).$$

La randomizzazione svolge un ruolo fondamentale perché rende, almeno in media, i gruppi di trattamento e controllo comparabili prima dell'intervento. In questo modo, eventuali differenze osservate negli outcome possono essere attribuite con maggiore credibilità al trattamento stesso, piuttosto che a differenze strutturali preesistenti tra i pazienti. Per questa ragione, gli RCT sono comunemente considerati il *gold standard* per la valutazione causale degli interventi clinici.

Tuttavia, anche nel contesto randomizzato la stima del CATE rimane un problema complesso.

### 1.2.3 Dati osservazionali e principali difficoltà

Al di fuori dei trial randomizzati, gran parte dei dati clinici disponibili è di natura osservazionale. In questi contesti, il trattamento non viene assegnato casualmente, ma dipende dalle caratteristiche del paziente, dalle condizioni cliniche, dalla storia terapeutica o dalle decisioni del medico. Di conseguenza, in generale vale:

$$P(T = 1 \mid X) \neq P(T = 1).$$

Questa dipendenza rende il problema causale molto più difficile, perché i gruppi trattati e non trattati non sono più direttamente comparabili. Le differenze osservate negli outcome possono infatti riflettere non solo l'effetto del trattamento, ma anche le differenze baseline tra i soggetti. È questo il caso classico del *confounding bias*, cioè della presenza di variabili che influenzano sia l'assegnazione del trattamento sia l'outcome.

Accanto al confondimento, nei dati osservazionali possono comparire altre criticità metodologiche. Tra queste vi sono il *selection bias*, che altera la composizione del campione osservato, e la mancanza di *overlap* o *positivity*, cioè l'assenza di sufficiente sovrapposizione tra le caratteristiche dei pazienti trattati e quelle dei controlli. Quando tali condizioni non sono soddisfatte, la stima del CATE diventa particolarmente instabile e può dipendere più dall'extrapolazione del modello che da un reale confronto tra individui comparabili.

### 1.2.4 Rilevanza del problema nel presente lavoro

Alla luce di queste considerazioni, il confronto tra contesto randomizzato e contesto osservazionale diventa particolarmente utile per studiare il comportamento dei modelli di stima del CATE. Un dataset RCT fornisce infatti un punto di partenza relativamente pulito dal punto di vista causale, mentre una sua versione pseudo-osservazionale consente di analizzare cosa accade quando vengono introdotte distorsioni tipiche della pratica reale. In questo modo è possibile valutare non solo la qualità delle stime ottenute, ma anche la loro stabilità rispetto alla presenza di bias e al cambiamento di distribuzione dei dati.

Nel contesto di questo lavoro, tali nozioni costituiscono la base teorica necessaria per interpretare sia la costruzione dei dataset sia il successivo confronto tra approcci di inferenza causale e modelli linguistici. L'idea di fondo è infatti verificare se strumenti non progettati originariamente per la causal inference, come i Large Language Models, siano in grado di produrre stime del CATE sensibili alla struttura dei dati e coerenti con la logica causale del problema.

## 1.3 Struttura del documento

Il presente elaborato è organizzato con l'obiettivo di illustrare in modo chiaro e sistematico il problema della stima del CATE in ambito clinico, il ruolo dei bias nei dati osservazionali e il comportamento dei Large Language Models in questo contesto. Il documento è strutturato come segue:

- **Capitolo 1: Introduzione.** In questo capitolo vengono presentati il contesto generale del lavoro, gli obiettivi del progetto e le principali nozioni teoriche necessarie per comprendere il problema affrontato, con particolare riferimento al CATE, ai trial randomizzati e ai dati osservazionali.
- **Capitolo 2: Analisi Dataset.** Il capitolo descrive i dataset considerati nel progetto e le relative caratteristiche, soffermandosi sia sui dati osservazionali sia sul dataset randomizzato utilizzato come riferimento. Vengono inoltre discusse le problematiche principali legate alla costruzione delle coorti, alla qualità dei dati e alla valutazione preliminare della loro idoneità per l'inferenza causale.
- **Capitolo 3: Bias Tools.** In questo capitolo vengono presentati gli strumenti sviluppati per trasformare un dataset inizialmente randomizzato in una versione pseudo-osservazionale. In particolare, vengono descritti i meccanismi di introduzione del *selection bias* e del *confounding bias*, insieme alle procedure di cleaning e armonizzazione finale del dataset.
- **Capitolo 4: LLM Prediction.** L'ultimo capitolo è dedicato all'analisi del comportamento dei Large Language Models nel task di predizione del CATE. Vengono illustrati l'obiettivo sperimentale, le modalità con cui i modelli sono stati interrogati e i principali risultati ottenuti, mettendoli a confronto con quelli prodotti da metodi causali più tradizionali.

---

---

# CAPITOLO 2

---

## ANALISI DATASET

### 2.1 Introduzione

L'obiettivo nella fase iniziale del lavoro è stato la costruzione e valutazione di dataset sia da RCT che osservazionali, derivati da dati clinici reali, con lo scopo di stimare ATE e CATE per le corrispondenti tuple.

A differenza degli RCT, i dati osservazionali presentano bias strutturali, tra cui confondimento, selezione e mancanza di overlap tra gruppi. Per questo motivo, una parte sostanziale del lavoro è stata dedicata alla ricerca e costruzione di dataset che, pur non essendo randomizzati, risultino sufficientemente adatti per applicare metodi di inferenza causale.

Le caratteristiche ricercate nei dataset sono state:

- **Trattamento:** binario e ben definito;
- **Outcome:** clinicamente significativo e temporalmente coerente;
- **Baseline:** disponibilità di covariate pre-trattamento;
- **Positivity:** sufficiente overlap tra trattati e controlli;
- **Campione:** numerosità adeguata e comparabile tra i due gruppi;
- **Variabilità:** nella decisione di trattamento (assenza di determinismo clinico).

Punto cruciale emerso fin dalle prime fasi, come atteso, la qualità dell'inferenza causale dipende molto più dalla qualità del dataset che dal modello utilizzato.

In una prima fase esplorativa, sono stati analizzati diversi dataset candidati, in particolar modo:

- Framingham heart study dataset
- MELODY Study dataset
- Medical Information Mart for Intensive Care IV (MIMIC-IV) [1]
- AIDS Clinical Trials Group Study 175 Dataset (ACTG 175) [2]

Il primo, sebbene contenente un numero elevato di soggetti, è un dataset osservazionale con un numero limitato di feature e si è preferito scartarlo in questa prima fase. MELODY è privato ma con possibilità di accesso tramite richiesta agli autori, che, tuttavia, non hanno risposto alle nostre richieste.

Pertanto, nelle sezioni successive verranno descritti i restanti due analizzati, MIMIC-IV e ACTG 175. In una prima fase, solo vari sottoinsiemi di MIMIC-IV sono stati realizzati e analizzati. La mancata identificazione di un subset RCT-like, con caratteristiche di nullo o limitato bias e elevata positivity, ha reso necessario l'uso di un dataset RCT puro, come ACTG 175, per avere una solida base per l'analisi del tool di bias e inferenza del CATE.

## 2.2 Dataset MIMIC-IV

MIMIC-IV è un database clinico pubblico che raccoglie dati de-identificati relativi a pazienti ricoverati in ospedale e nei reparti di terapia intensiva (ICU). La scelta di questo database è motivata dalla sua idoneità per gli studi di inferenza causale: la ricchezza delle variabili cliniche e demografiche disponibili permette infatti di costruire scenari realistici di trattamenti non randomizzati, simulando le condizioni e le distorsioni tipiche dei dati osservazionali.

MIMIC-IV si distingue per essere un dataset estremamente ricco ma, al contempo, complesso, caratterizzato da dati longitudinali ad alta granularità temporale. Le informazioni dei pazienti sono strutturate in diverse tabelle relazionali.

Per la costruzione della baseline e l'estrazione delle covariate cliniche, sono state interrogate principalmente le seguenti tabelle: **chartevents** per il monitoraggio continuo dei parametri vitali (es. frequenza cardiaca, pressione, saturazione), **labevents** per i risultati degli esami di laboratorio, **inputevents** per tracciare le somministrazioni farmacologiche in continuo e i fluidi, **procedureevents** per le procedure cliniche effettuate (es. intubazione) e **admissions** per le informazioni relative all'esito del ricovero, come la mortalità intraospedaliera.

In aggiunta ai dati clinici, per caratterizzare adeguatamente lo stato iniziale dei pazienti e controllare potenziali bias di confondimento, sono stati estratti dati demografici e antropometrici (come età, sesso, etnia, peso, altezza e BMI). A seconda della specifica pipeline di estrazione, questi dati sono stati recuperati interrogando direttamente le tabelle grezze del database (**patients**, **admissions** e **omr**) oppure sfruttando le viste materializzate fornite dal modulo **mimiciv\_derived** sviluppato dal MIT (nello specifico le viste **icustay\_detail**, **age**, **height**, **first\_day\_weight** e **weight\_durations**), che offrono aggregazioni pre-calcolate e standardizzate.

L'utilizzo di dati di derivazione clinica reale introduce diverse sfide metodologiche. Tra le principali criticità affrontate vi sono l'elevata eterogeneità delle misurazioni, la necessità di convertire unità di misura (es. da sistema imperiale a metrico per le misurazioni antropometriche) e la gestione della missingness. Infine, ai fini dell'inferenza causale, è stato necessario definire rigorosamente il "tempo zero" ( $t_0$ ) per ciascun paziente e gestire opportunamente la dipendenza temporale tra le variabili cliniche per evitare di includere covariate post-trattamento (collider bias).

Il dataset utilizzato è MIMIC-IV, un database clinico pubblico contenente dati de-identificati di pazienti ricoverati o in terapia intensiva. Si tratta di un dataset altamente ricco ma anche estremamente complesso.

Di seguito, un schema riassuntivo della somma di caratteristiche e tabelle usate per la data selection in MIMIC-IV e descritte precedentemente.

Le principali caratteristiche includono:

- dati longitudinali ad alta granularità temporale;
- presenza di diverse tabelle relazionali (vitali, laboratori, farmaci, procedure);
- ampia variabilità tra pazienti;
- elevata percentuale di dati mancanti.

Le tabelle principali utilizzate sono:

- `chartevents`: parametri vitali;
- `labevents`: esami di laboratorio;
- `inputevents`: somministrazioni farmacologiche;
- `procedureevents`: procedure cliniche;
- `admissions`: informazioni di outcome (es. mortalità).

Le principali difficoltà identificate:

- eterogeneità delle misurazioni;
- mancanza di standardizzazione;
- presenza di bias clinici nella scelta dei trattamenti;
- dipendenza temporale tra variabili.

### 2.2.1 Scenari Clinici e Coorti Estratte

Al fine di testare i modelli per la stima del CATE su diverse casistiche cliniche, l'architettura di estrazione è stata strutturata in pipeline modulari. Ciascuna pipeline è dedicata alla costruzione di un dataset pseudo-osservazionale incentrato su una specifica decisione clinica in terapia intensiva. Sono stati effettuati numerosi test sia con trattamenti e outcome diversi sia raffinamenti iterativi su uno stesso dataset, determinando, ad esempio valori diversi per il reclutamento nel subset in fase di studio, al fine di ridurre il bias e migliorare l'overlap.

Di seguito, viene descritta solo una selezione dei principali scenari implementati, che aiutano a trarre diverse conclusioni su pipeline, modelli e caratteristiche dei dati ed evidenziare le principali difficoltà della stima del CATE:

**Uso Precoce di Vasopressori** Questo dataset si concentra sulla somministrazione tempestiva di vasopressori (entro 6 ore) in area critica. La definizione del trattamento si basa sugli eventi registrati in `inputevents` per farmaci quali noradrenalina, adrenalina e dopamina. Per questa coorte è stata costruita una baseline estesa di esami di laboratorio (es. lattati, creatinina, WBC) e parametri vitali acquisiti rigorosamente nella finestra antecedente l'esposizione.

**Trasfusioni di Globuli Rossi (RBC)** Lo scenario indaga l'impatto delle trasfusioni di emazie in pazienti con livelli di emoglobina critici. Il tempo zero è definito dal riscontro del primo valore di emoglobina compreso tra 7.5 e 8.5 g/dL ( $0 \leq 8.5$  g/dL a seconda della versione della pipeline) entro 48 ore dall'ammissione.

Il trattamento è registrato se la trasfusione avviene entro 3-4 ore dal  $t_0$ , analizzando la conseguente mortalità ospedaliera.

**Sepsi e Somministrazione di Steroidi** Questo scenario valuta l'effetto della somministrazione di corticosteroidi in pazienti adulti con diagnosi di sepsi entro le prime 24 ore dall'ingresso in ICU.

Il trattamento è definito tramite l'identificazione delle prescrizioni (prescriptions) e la conversione dei dosaggi in idrocortisone-equivalenti (considerando trattati i pazienti con dosi  $\geq 160$ mg).

L'outcome primario valutato è la mortalità intraospedaliera e a 28 giorni. Per questa coorte è stato fatto ampio uso dei concetti pre-calcolati dal modulo `mimiciv_derived` (es. criteri Sepsis-3, SOFA score).

**Somministrazione Precoce vs Tardiva di Diuretici** In questo scenario, con pazienti settici ricoverati in terapia intensiva, il confronto è tra somministrazione precoce di diuretici dell'ansa e strategia tardiva o assente.

Il razionale clinico è legato alla fase di *de-resuscitation*: un intervento precoce può favorire la riduzione del sovraccarico di fluidi nei pazienti congesti, ma può risultare dannoso nei soggetti ancora instabili dal punto di vista emodinamico.

Il trattamento è definito in funzione del timing rispetto al  $t_0$ , mentre l'outcome principale resta la mortalità intraospedaliera a 28 giorni. Questo subset è stato incluso perché rappresenta un contesto di reale incertezza decisionale, con maggiore variabilità clinica rispetto a scenari più deterministici.

In generale, i dettagli metodologici e i risultati di ogni dataset sono discussi nelle sottosezioni successive.

## 2.3 Pipeline di Costruzione del Dataset

L'estrazione di coorti osservazionali da cartelle cliniche elettroniche (EHR) ad alta granularità come MIMIC-IV richiede un'architettura rigorosa. Per soddisfare le assunzioni fondamentali dell'inferenza causale e permettere ai modelli di stima del CATE di apprendere rappresentazioni corrette (senza inquinamento temporale tra le variabili), il processo di costruzione di ciascun subset è stato standardizzato attraverso una pipeline sequenziale, suddivisa nei seguenti passaggi logici.

### 2.3.1 Definizione del tempo zero

Il *tempo zero* ( $t_0$ ) costituisce l'ancora temporale attorno alla quale ruota l'intero campionamento dei dati per ogni singolo paziente. Rappresenta il momento clinico in cui il paziente soddisfa i criteri di eleggibilità per lo scenario in esame (ad esempio, momento di ospedalizzazione, il momento della diagnosi di sepsi, il primo calo critico di emoglobina, o l'inizio del supporto respiratorio) e corrisponde, idealmente, al momento in cui il medico valuta la decisione terapeutica. Definire un  $t_0$  rigoroso è cruciale per evitare l'immortal time bias e per allineare temporalmente i pazienti, indipendentemente dal momento in cui sono stati ricoverati in terapia intensiva.

### 2.3.2 Definizione del trattamento (T)

Il trattamento viene definito come una variabile binaria:

$$\mathbf{T} \in \{0, 1\}$$

dove il valore dipende dalla presenza o meno di una specifica procedura o intervento in una finestra temporale successiva a ( $t_0$ ).

Per formulare il problema come tale, la condizione di trattamento è stata verificata all'interno di una finestra temporale clinicamente rilevante e strettamente successiva o concomitante al  $t_0$ . A seconda del subset:

- Sono stati estratti gli eventi di somministrazione farmacologica o procedurale (es. da `inpatientevents` o `prescriptions`).
- Sono state applicate regole logiche per definire la validità del trattamento, come soglie di dosaggio minimo (es. steroidi in dosi  $\geq 160\text{mg}$  idrocortisone-equivalenti) o etichette maggioritarie per trattamenti concorrenti (es. scelta tra HFNC e NIV).

### 2.3.3 Definizione dell'outcome (Y)

L'outcome ( $\mathbf{Y}$ ) è stato definito sempre come una **variabile binaria** che rappresenta un evento (es. intubazione, mortalità) osservato in una finestra temporale successiva al trattamento.

In particolare, essa è stata misurata in un orizzonte temporale prospettico rispetto al  $t_0$ . Gli outcome estratti sono di natura clinica concreta e includono sia metriche binarie (es. mortalità intraospedaliera, mortalità a 28 giorni dal  $t_0$ , sia eventi clinici procedurali valutati entro finestre temporali predefinite (es. necessità di intubazione entro 48 ore).

L'assegnazione dell'outcome utilizza principalmente i timestamp di dimissione o decesso presenti nella tabella admissions, confrontandoli con l'ancora temporale del paziente.

### 2.3.4 Finestre di estrazione delle covariate (Baseline e History)

Il vettore delle covariate cliniche ( $\mathbf{X}$ ) che descrive lo stato del paziente deve contenere esclusivamente informazioni antecedenti all'assegnazione del trattamento. Includere variabili post-trattamento violerebbe l'assunzione causale, introducendo distorsioni (collider bias). Per questo motivo, le covariate vitali, ematochimiche e i punteggi di gravità sono stati estratti definendo una finestra di lookback specifica per ogni variabile rispetto al  $t_0$ , ad esempio:

$$[-6h, +0h].$$

Tuttavia, il range è stato modificato, in base alle caratteristiche delle feature estratte, in un intervallo generale  $[-24h, +3h]$ .

Nella maggior parte dei test effettuati, inoltre, è stato utilizzato un *grace period* (per lo più  $0.5 - 1h$ ) per alcuni set di feature come le analisi laboratoriali. Ciò è reso necessario in quanto gli orari di tali operazioni sono spesso differiti rispetto al tempo riportato di ospedalizzazione. Questo delay è stato osservato in genere tra il 50-80% delle tuple analizzate.

Per la gestione della continuità dei dati, la pipeline adotta un approccio "last-observation-carried-forward" all'interno della finestra di riferimento, estrapolando l'ultima misurazione clinica valida registrata prima del tempo zero.

### 2.3.5 Criteri di inclusione ed esclusione

L'ultimo passaggio della pipeline filtra la coorte finale applicando vincoli clinici e metodologici. Tra le procedure di esclusione standard applicate figurano:

- Inclusione esclusiva di pazienti adulti (età  $\geq 18$  anni).
- Selezione del primo ricovero in ICU per ciascun paziente, scartando i successivi per garantire l'indipendenza delle osservazioni (i.i.d.).
- Esclusione dei pazienti che hanno ricevuto il trattamento in studio in un momento antecedente all'inizio del follow-up ( $t < t_0$ ), per garantire che l'effetto misurato sia interamente imputabile alla decisione clinica presa al tempo zero.

### 2.3.6 Costruzione delle covariate baseline

A seguito dell'identificazione dei criteri e della finestra di selezione migliore, ogni subset è stato costruito unendo una serie di feature in parte generalizzabili, in parte specifiche in base al caso clinico in studio.

Le principali feature generalizzabili includono:

- parametri vitali (HR, RR, SpO2, pressione);
- esami di laboratorio (creatinina, lattato, INR);
- dati demografici;
- indicatori di trattamento pregresso (es. vasopressori);
- indicatori di missingness.

### 2.3.7 Cleaning e preprocessing

Sono state effettuate diverse operazioni di pulizia:

- conversione di unità di misura;
- gestione dei valori mancanti;
- rimozione di outlier evidenti;
- creazione di indicatori binari di missingness.

## 2.4 Metodologia di Analisi e Validazione Causale

Una volta ultimata l'estrazione delle coorti, i dataset pseudo-osservazionali ottenuti sono stati sottoposti a una rigorosa pipeline di analisi causale.

L'obiettivo di questa fase è stato valutare la qualità della baseline, misurare l'entità del bias di confondimento (confounding by indication) e procedere con la stima dell'effetto medio (ATE) e condizionato (CATE) del trattamento.

L'intera architettura di validazione e stima è stata progettata per essere completamente dataset-agnostic: il codice non dipende da specifiche colonne o logiche hard-coded, ma viene orchestrato dinamicamente tramite un oggetto di configurazione (una dataclass denominata `BaselineConfig`).

Questo approccio garantisce la riproducibilità dell'esperimento su qualsiasi coorte. La configurazione permette di mappare in modo flessibile per ciascun scenario:

- Le variabili strutturali (identificativo del paziente, colonna del trattamento, colonna dell'outcome).
- I parametri di validazione incrociata (es. numero di fold per il cross-fitting).
- Le feature da scartare in fase di addestramento (`drop_cols`) per evitare data leakage.
- I parametri di troncamento statistico e le regole di assegnazione terapeutica (`policy`), che variano a seconda del contesto clinico.

Di seguito vengono descritte le fasi analitiche applicate a ogni configurazione.

### 2.4.1 Stima del Propensity Score e Ponderazione

Il primo passo dell'analisi consiste nella stima del Propensity Score (PS), definito come la probabilità condizionata di ricevere il trattamento date le covariate pre-trattamento:

$$e(x) = P(T = 1 \mid X = x).$$

Per catturare eventuali relazioni non lineari, il PS è stato stimato utilizzando modelli di Histogram-based Gradient Boosting.

L'analisi del PS ha previsto:

- Lo studio della distribuzione del punteggio nei gruppi di trattati e controllo per verificare l'assunzione di positivity.
- L'applicazione di tecniche di clipping (troncamento delle probabilità estreme, tipicamente tra 0.01 e 0.99, o 0.05 e 0.95 a seconda della configurazione) per evitare instabilità numeriche nella successiva fase di ponderazione.

A partire dal PS, sono stati calcolati i pesi per bilanciare il campione, utilizzando approcci come l'IPTW (Inverse Probability of Treatment Weighting) e l'ATO (Average Treatment Effect for the Overlap Population).

La stabilità dei pesi è stata monitorata verificando l'assenza di outlier estremi e calcolando l'Effective Sample Size (ESS).

### 2.4.2 Valutazione del Bilanciamento

Il bilanciamento delle covariate tra il gruppo dei trattati e quello dei controlli è stato quantificato tramite la Standardized Mean Difference (SMD). Un valore pre-weighting elevato di SMD indica una forte differenza strutturale tra i due gruppi, segnale diretto della presenza di confounding bias. Si è deciso di rimuovere alcune feature con elevato SMD laddove possibile o di decretare il dataset con bias troppo elevato per procedere ad analisi più approfondite laddove l'importanza o il numero di tali feature fossero tali da rendere il dataset non veritiero in caso di rimozione.

La qualità del dataset e l'efficacia del PS vengono considerate soddisfacenti se, a seguito della ponderazione, la SMD scende sotto la soglia di tolleranza convenzionale ( $< 0.1$  ideale,  $< 0.3$  tollerato) per la maggior parte delle feature cliniche.

L'arricchimento del set di covariate (es. inserimento del SOFA score e dei biomarcatori) si è rivelato fondamentale per ridurre i valori di SMD residui.

### 2.4.3 Stima dell'Effetto Causale (DR-Learner)

Per la stima dell'effetto eterogeneo (CATE,  $\tau(x)$ ), è stata adottata un'architettura basata su DR-Learner (Doubly Robust Learner) con cross-fitting.

Questo meta-learner combina tre componenti:

1. Il modello di Propensity Score.
2. Due modelli di outcome separati, addestrati rispettivamente sui trattati ( $m_1$ ) e sui controlli ( $m_0$ ).
3. Una regressione finale applicata su uno pseudo-outcome.

Lo pseudo-outcome  $\phi$  è calcolato come:

$$\phi = (m_1 - m_0) + \frac{T(Y - m_1)}{e} - \frac{(1 - T)(Y - m_0)}{1 - e}$$

Questo approccio garantisce la proprietà di *doppia robustezza*: la stima finale dell'effetto causale risulta consistente se almeno uno tra il modello di trattamento (PS) e il modello di outcome è specificato in modo corretto.

### 2.4.4 Policy Learning ed Eterogeneità

A partire dalle stime individuali del CATE ( $\tau(x)$ ), è possibile definire regole di assegnazione terapeutica (policy) del tipo:

$$\pi(x) = \mathbf{1}[\tau(x) > t]$$

dove  $t$  rappresenta una soglia decisionale. L'efficacia della policy derivata dal modello è stata valutata confrontandola con strategie naive (come **treat-all** o **treat-none**) tramite il calcolo del DR policy value.

Le analisi hanno incluso anche lo studio delle curve di valore al variare della soglia (threshold analysis) e la stima degli intervalli di confidenza tramite bootstrap.

La calibrazione del CATE è stata inoltre ispezionata per capire se il modello fosse in grado di separare nettamente sottopopolazioni con risposte opposte al trattamento.

### 2.4.5 Policy Learning e Regole Decisionali

A partire dalle stime individuali del CATE ( $\tau(x)$ ), sono state definite regole di assegnazione terapeutica, denominate policy ( $\pi(x)$ ). Data l'eterogeneità dei dataset analizzati, la pipeline adatta automaticamente la regola della policy in base alla natura dell'outcome e alla metrica **tau\_direction** specificata nella configurazione:

- **Policy**  $\tau < 0$  (tau\_lt\_0 / lte): Utilizzata per la maggior parte dei task clinici in cui l'outcome rappresenta un evento avverso (es. mortalità a 28 giorni per la sepsi, intubazione per il supporto respiratorio). In questi casi, un CATE negativo indica che il trattamento riduce il rischio dell'evento. La policy assegna quindi il trattamento ai soli pazienti per i quali  $\tau \leq 0$ .

- **Policy**  $\tau > 0$  (`tau_gt_0 / gte`): Adottata nei casi in cui l'outcome misuri un evento positivo (es. guarigione, progressione favorevole). In queste configurazioni, il trattamento è considerato benefico se aumenta la probabilità dell'outcome, e la policy tratta i pazienti con  $\tau(x) \geq 0$ .
- **Policy Top Fraction** (`top_frac_benefit`): Per scenari che simulano vincoli di risorse o in cui è clinicamente opportuno trattare solo i soggetti con il beneficio massimo (es. somministrazione tempestiva di diuretici), la policy seleziona unicamente il percentile superiore dei pazienti (es. `top_frac` = 0.2, ovvero il 20% della coorte) ordinati per magnitudo del beneficio atteso.

L'efficacia della policy derivata dal modello è stata infine valutata confrontandola con strategie naive (come `treat-all` o `treat-none`) tramite il calcolo del DR policy value.

## 2.5 Risultati Sperimentali e Analisi in MIMIC-IV

In questa sezione vengono presentati e discussi criticamente i risultati ottenuti dall'applicazione della pipeline di inferenza causale ai diversi scenari clinici estratti da MIMIC-IV. L'obiettivo è duplice: da un lato, quantificare l'effetto medio e individuale dei trattamenti in esame; dall'altro, valutare la robustezza metodologica di ciascun dataset in termini di sovrapposizione (overlap), bilanciamento delle covariate e reale utilità clinica delle policy decisionali (Policy Learning) basate sul CATE.

Per ogni subset verranno analizzate la composizione della coorte, la qualità del bilanciamento pre- e post-ponderazione, le stime dell'Effetto Medio del Trattamento (ATE) e le performance delle regole di assegnazione terapeutica personalizzate rispetto a strategie decisionali uniformi.

### 2.5.1 Uso Precoce di Vasopressori in Terapia Intensiva (`vaso_v0`)

Questo primo scenario è stato analizzato come esperimento preliminare per familiarizzare con l'infrastruttura di MIMIC-IV e con la pipeline causale. L'obiettivo teorico era valutare l'effetto della somministrazione precoce di vasopressori (entro le prime 6 ore) rispetto all'outcome di mortalità ospedaliera (`y_hosp_mort`).

#### Composizione del Campione e Covariate

La coorte finale estratta è risultata molto ampia, comprendendo 65.281 osservazioni, suddivise in un set di addestramento (45.697) e uno di test (9.792). All'interno del test set, il tasso di incidenza dell'outcome è stato del 10.64%, con una percentuale di trattati del 23.2%. Per la modellazione del baseline sono state impiegate 64 feature numeriche e 2 categoriche.

### Analisi del Bilanciamento e Stima dell'Effetto

Le analisi diagnostiche sul Propensity Score (PS) hanno evidenziato un overlap mediocre, pur con una coda bassa nel gruppo di controllo (minimo complessivo pari a 0.0029). L'applicazione di tecniche di ponderazione ha mostrato che:

- Il metodo IPTW non è riuscito a bilanciare adeguatamente il campione, lasciando quasi il 30% delle feature con una Standardized Mean Difference (SMD)  $> 0.1$ .
- L'approccio ATO ha invece prodotto un bilanciamento eccellente (SMD medio crollato da 0.298 a 0.027), sebbene la Proteina C-Reattiva (PCR) sia rimasta la variabile più sbilanciata.

Sia l'Effetto Medio (ATE), stimato tra +0.04 e +0.06, sia il CATE individuale hanno indicato un rischio sistematicamente maggiore per i pazienti trattati. Nello specifico, il modello ha predetto un effetto dannoso (CATE $>0$ ) per il 99.88% dei pazienti, portando le valutazioni di policy a suggerire una strategia `treat=none` ("non trattare nessuno") come soluzione ottima.

### Discussione Critica del Dataset

Dal punto di vista puramente statistico, la pipeline ha funzionato correttamente, ma dal punto di vista clinico il risultato è paradossale: i vasopressori sono farmaci salvavita indispensabili negli stati di shock profondo.

La conclusione di *"non trattare"* non riflette una reale dannosità del farmaco, ma è la manifestazione di un **forte bias di confondimento per indicazione** (confounding by indication). I vasopressori sono stati somministrati esclusivamente ai pazienti in condizioni emodinamiche critiche.

Nonostante l'ampio numero di covariate, il modello non è riuscito a catturare la reale gravità (non misurata o latente) dello shock iniziale, associando così in modo spurio la somministrazione del farmaco all'alta mortalità tipica di questi quadri clinici.

### 2.5.2 Trasfusioni di Globuli Rossi (RBC) in Pazienti Critici (rbc\_v1\_fixed)

Il secondo dataset preliminare è stato incentrato sulle trasfusioni di globuli rossi (RBC) per pazienti in area critica. In questa fase, è stato svolto un lungo lavoro di fine-tuning sui parametri di inclusione per tentare di costruire un'area di reale incertezza decisionale. Sono stati selezionati pazienti non in evidente stato di shock (con lattati normali o non misurati) e con valori di emoglobina (Hb) "borderline" (tra 7.5 e 10.5 g/dL), per i quali la decisione trasfusionale risultava meno scontata.

### Composizione del Campione

La coorte ha incluso un totale di 15.612 pazienti (10.928 in addestramento, 2.342 in test). Nel set di valutazione, la mortalità è stata del 13.15% e il tasso di trattamento (trasfusione entro 3 ore dal tempo zero) si è attestato al 13.88%.

### Collasso del Propensity Score e Violazione dell'Overlap

Nonostante i rigorosi filtri clinici applicati a monte, l'analisi del baseline ha fatto emergere una compromissione strutturale del dataset.

L'ispezione della probabilità di assegnazione al trattamento ha mostrato una separazione quasi totale tra i gruppi:

- Per i controlli, il PS si è stabilizzato su valori infinitesimali (nell'ordine di  $10^{-7}$ ).
- Per i trattati, il PS ha raggiunto valori vicinissimi a 1 ( $\sim 0.999$ ).

L'assenza di sovrapposizione ha reso del tutto inefficaci i metodi di ponderazione. Anche dopo l'applicazione dei pesi IPTW e ATO, la SMD massima è rimasta superiore a 0.6, con quasi il 70% delle feature clinicamente rilevanti (es. `has_lactate`, `has_hb_prior`, `t0_hb`) fortemente sbilanciate.

### Discussione Critica del Dataset

Le stime di ATE e CATE estratte da questo dataset (che suggerivano un lieve beneficio medio del trattamento) e le conseguenti policy sono risultate metodologicamente inaffidabili.

La separazione estrema del PS ha dimostrato una chiara violazione dell'assunzione di positivity. Questo indica che la decisione medica di trasfondere in questi pazienti è stata essenzialmente deterministica e guidata da pattern specifici (es. emorragie acute non documentate dalle sole variabili strutturate) che dividevano perfettamente le due popolazioni.

In assenza di overlap, i modelli di stima del CATE sono stati costretti a operare in pura estrapolazione matematica. Per tale ragione, questo scenario è stato scartato come candidato per l'inferenza causale, confermando l'importanza di strumenti diagnostici rigorosi prima di validare qualsiasi policy automatica.

### 2.5.3 Corticosteroidi nella Sepsis (sepsis\_v2)

L'analisi di questo scenario è stata guidata dall'ipotesi clinica che i corticosteroidi, pur non essendo universalmente benefici, possano ridurre drasticamente la mortalità in un sottogruppo specifico di pazienti caratterizzato da shock refrattario o fenotipo iperinfiammatorio. Tuttavia, i risultati ottenuti hanno mostrato una divergenza significativa tra la teoria della letteratura e l'evidenza empirica estratta dal dataset MIMIC-IV.

## Contesto e Configurazione Sperimentale

È stata analizzata una coorte di 23.637 pazienti con sepsi, definendo come trattamento la somministrazione precoce di steroidi (`treat_steroid`) e come outcome la mortalità a 28 giorni.

- **Popolazione:** 16.545 pazienti per il training e 3.546 per il test.
- **Sbilanciamento di Classe:** Solo l'11,8% dei pazienti nel test set ha ricevuto il trattamento, riflettendo una pratica clinica conservativa (raccomandazione debole delle linee guida).
- **Outcome Rate:** Una mortalità osservata del 14,89%, indicativa di una popolazione ad alta criticità.

### 2.5.4 Analisi del Propensity Score e Bilanciamento

Le analisi diagnostiche hanno evidenziato una delle prime criticità metodologiche:

- **Distribuzione Schiacciata:** Come ipotizzato, il Propensity Score è risultato tendenzialmente molto basso e compresso verso lo zero (mediana 0,078) (Figura 2.1a). Questo ha indicato che, sulla base delle covariate fornite, la stragrande maggioranza dei pazienti aveva una probabilità prevista di trattamento estremamente ridotta.
- **Overlap:** Nonostante i valori bassi, non sono state riscontrate violazioni della positivity (range 0,01 - 0,68), eliminando la necessità di clipping.
- **Bilanciamento Residuo:** L'uso dei pesi (IPTW e ATO) ha migliorato il bilanciamento per circa il 73% delle feature, ma sono rimasti sbilanciamenti significativi ( $SMD > 0,20$ ) su variabili critiche come la saturazione di ossigeno (`so2`) e parametri antropometrici.




Figura 2.1: Principali plot per `sepsis_v2`: Le distribuzioni di PS sono fortemente sbilanciate verso valori bassi ma discreta overlap (a) mentre la curva di policy (b) mostra un sottogruppo promettente per la personalizzazione ma una soglia molto rigida in cui `treat-all` peggiora l'outcome per un gran numero di pazienti.

## Risultati del Modello Causale (ATE e CATE)

L'applicazione del DR-Learner ha prodotto risultati coerenti ma clinicamente sfavorevoli all'ipotesi di partenza:

- **Effetto Medio (ATE):** Tutti gli stimatori (AIPW: +0,041; IPTW: +0,054) hanno concordato su un effetto dannoso medio. La somministrazione di steroidi è stata associata a un incremento della mortalità stimato tra il 4% e il 5%.
- **Eterogeneità CATE:** La distribuzione dell'effetto individuale è risultata quasi interamente confinata nel dominio positivo (danno) (Figura 2.1b):
  - Il 99,49% dei pazienti ha mostrato un  $\tau > 0$ .
  - Solo lo 0,51% del campione ha mostrato un potenziale beneficio ( $\tau < 0$ ).

## Policy Learning e Curve di Soglia

La valutazione della policy ha confermato la superiorità delle strategie conservative:

- **Dominanza di `treat-none`:** La strategia di non trattare nessuno ha prodotto una mortalità attesa del 14,58%, nettamente migliore rispetto a `treat-all` (19,01%).
- **Ottimizzazione della Soglia:** La Threshold Curve ha mostrato un andamento estremamente ripido. Spostando la soglia di intervento anche di poco, il valore della policy è crollato rapidamente verso il valore di `treat-all`, indicando una scarsa robustezza della personalizzazione.

## Sintesi Critica Dataset

Il dataset `sepsis_v2` è stato considerato qualitativamente inferiore rispetto a `diur_v1` per le seguenti ragioni:

- **Assenza Segnale di Beneficio:** Mentre la letteratura suggerisce l'esistenza di un sottogruppo iper-infiammatorio che trae vantaggio dagli steroidi, le feature presenti nel dataset (seppur numerose) non sono state in grado di isolarlo. Mancando marker specifici (come IL-6 o traiettorie citochiniche avanzate), il modello ha visto solo l'associazione tra "paziente più grave" e "trattamento", interpretandola come danno causale.
- **Instabilità delle Soglie (Steep Thresholds):** La distribuzione del CATE molto compressa ha reso la policy estremamente sensibile. Una minima variazione nei parametri del modello avrebbe ribaltato la decisione per migliaia di pazienti, rendendo la policy inaffidabile per un contesto clinico reale.
- **Propensity Score Sbilanciato:** Il fatto che il PS fosse così "schiacciato" verso il basso ha reso il peso dei pochi pazienti trattati molto alto nelle stime IPTW, aumentando il rischio che i risultati fossero guidati da pochi outlier piuttosto che da un vero segnale biologico.
- **Incertezza Inferenziale:** Sebbene l'ATE puntuale fosse positivo (danno), gli intervalli di confidenza bootstrap per AIPW sono risultati molto ampi (da -0,07 a

+0,15), indicando che il dataset non possedeva la potenza statistica necessaria per confermare l'effetto in presenza di un bilanciamento delle covariate imperfetto.

In definitiva, `sepsis_v2` ha fallito nel dimostrare l'utilità del CATE per la medicina di precisione. Il segnale di "danno universale" rilevato dal modello, in contrasto con la letteratura, suggerisce la presenza di un forte bias residuo o la mancanza di variabili discriminanti fondamentali. Al contrario, il dataset sui diuretici ha presentato un overlap più sano e una risposta eterogenea più strutturata, venendo quindi preferito per le analisi finali della tesi.

### 2.5.5 Somministrazione Precoce di Diuretici nella Sepsì (`diur_v1`)

#### Composizione del Campione

Questo scenario analizza l'effetto della somministrazione precoce (rispetto a una somministrazione ritardata o assente) di terapia diuretica in pazienti adulti ricoverati in terapia intensiva con diagnosi di sepsi. L'outcome primario valutato è la mortalità intraospedaliera a 28 giorni (`y_28d_mort_inhosp`).

Il campione totale è composto da 6.216 osservazioni, suddivise in un set di addestramento (4.352 pazienti) e un test set (932 pazienti). All'interno del set di valutazione, l'incidenza dell'outcome (mortalità osservata) si attesta intorno al 9.76%, con una prevalenza del trattamento (diuretici precoci) pari al 53.8%.

#### Contesto e Razionale Clinico

La scelta di analizzare il timing della somministrazione dei diuretici dell'ansa (fase di de-resuscitation) in pazienti con sepsi è stata dettata dalla necessità di operare in un contesto di reale incertezza clinica. A differenza dei vasopressori, il cui uso è strettamente guidato dallo stato di shock, l'uso dei diuretici dopo la fase iniziale di rianimazione con fluidi non è uno standard-of-care universale, ma dipende fortemente dalla valutazione soggettiva del medico sul bilancio idrico del paziente.

In letteratura, il dibattito tra approccio precoce (early) e ritardato (delayed) è estremamente attuale. La razionale clinica per la personalizzazione del trattamento si basa su:

- **Eterogeneità della risposta:** Il beneficio è plausibile nei pazienti con sovraccarico di liquidi (fluid overload), ipossiemia o disfunzione renale lieve/borderline, dove la rimozione dei fluidi riduce la pressione idrostatica polmonare e il congestionamento venoso renale [3, 4].
- **Rischio di danno:** Al contrario, una rimozione aggressiva di liquidi in pazienti ancora ipovolemici o con instabilità emodinamica può precipitare un'insufficienza renale acuta (AKI) severa o ridurre la gittata cardiaca [5, 6].
- **Idoneità per l'inferenza causale:** Questo scenario è risultato ottimale per una simulazione RCT-like poiché il Propensity Score non è risultato estremo; la decisione medica non è stata deterministica, lasciando spazio a un confronto bilanciato tra pazienti trattati e non trattati in condizioni cliniche simili.

## Covariate di Baseline e Analisi del Confounding

Per descrivere lo stato iniziale dei pazienti e mitigare i bias di selezione, sono state utilizzate 38 covariate (36 numeriche e 2 categoriche). Da un punto di vista clinico, le variabili che hanno mostrato le maggiori discrepanze tra i due gruppi includono indici di funzionalità renale (bun, creatinina), parametri ematologici e di coagulazione (wbc, inr), temperatura corporea e instabilità emodinamica (necessità di vasopressori al baseline). Queste feature sono indicatori diretti della gravità metabolica e infettiva del paziente, rappresentando di fatto il principale motore del confounding by indication.

L'analisi del Propensity Score mostra un ottimo supporto empirico: non si evidenziano campioni al di fuori dei limiti di clipping (0.01 - 0.99) e le distribuzioni non presentano separazioni nette, come visibile in Figura 2.2.




Figura 2.2: Distribuzione del Propensity Score per gruppo Trattati vs Controllo nel dataset `diur_v1`.

Tuttavia, nonostante la buona stabilità dei pesi (specialmente utilizzando l'approccio ATO, che ha garantito un Effective Sample Size elevato pari a 782.5 su 932), il bilanciamento post-ponderazione risulta incompleto.

Anche dopo l'applicazione dei pesi, variabili cliniche critiche come temperatura, funzionalità renale (BUN) e uso di vasopressori mantengono una Standardized Mean Difference (SMD) superiore alla soglia ottimale dello 0.1 (con picchi fino a 0.19 per ATO e 0.24 per IPTW), sebbene ben al di sotto del limite tollerabile di 0.3. Questo indica la persistenza di un bias di confondimento residuo non trascurabile ma migliore di altri subset individuati.

## Stima dell'Effetto Causale (DR-Learner)

Le stime puntuali dell'Effetto Medio del Trattamento (ATE) suggeriscono un potenziale ruolo protettivo dei diuretici precoci. I modelli indicano una riduzione media del rischio di mortalità compresa tra il 3.5% (stimatore ATO) e il 6.6% (stimatore AIPW). Analizzando l'eterogeneità dell'effetto tramite DR-Learner, la distribuzione del CATE mostra una media coerente con l'ATE ( $-0.011$ ) ma un'elevata dispersione (Standard Deviation pari

a 0.189). Questo suggerisce la potenziale presenza di sottogruppi di pazienti con risposte diametralmente opposte alla terapia.

Ciononostante, sul piano inferenziale l'incertezza rimane elevata: gli intervalli di confidenza calcolati via bootstrap attraversano lo zero per tutti gli stimatori analizzati, impedendo di trarre conclusioni statisticamente robuste sull'efficacia del trattamento a livello di intera popolazione.

## Valutazione delle Policy Decisionali

L'efficacia della stima del CATE è stata testata confrontando una policy personalizzata (che assegna il trattamento solo ai pazienti con beneficio predetto) con strategie uniformi.

I risultati della valutazione doppiamente robusta (DR Value) sul test set indicano che:

- La strategia **treat-none** produce la mortalità attesa peggiore (13.44%).
- La policy personalizzata migliora l'esito rispetto al non trattare, attestandosi a una mortalità attesa del 12.16%.
- La strategia uniforme **treat-all** ("trattare tutti") risulta essere in assoluto la policy dominante, abbassando la mortalità attesa all'8.64%.

Analizzando la curva di soglia (Threshold Curve), emerge che il beneficio massimo si ottiene abbassando la soglia di inclusione fino a trattare tra l'85% e il 99% della popolazione, come mostrato in Figura 2.3.




Figura 2.3: Curva del Valore della Policy (Mortalità) al variare della soglia (Threshold Curve) per `diur_v1`.

Un'analisi granulare per bin di rischio evidenzia che il guadagno clinico derivante dal trattamento è fortemente concentrato nei pazienti ad altissimo rischio, mentre nei bin a basso e medio rischio il modello suggerisce un potenziale over-treatment, che però non è sufficiente a ribaltare la superiorità matematica della regola "trattare tutti" (Figura 2.4).




Figura 2.4: Beneficio atteso o Mortalità stratificata per Bin di Rischio per `diur_v1`.

## Conclusioni Critiche e Confronto con la Letteratura

L'analisi condotta sul dataset `diur_v1` ha prodotto risultati che, sebbene coerenti internamente, hanno richiesto un'attenta interpretazione critica. Mentre studi recenti suggeriscono che una somministrazione indiscriminata di diuretici possa essere associata a outcome peggiori o neutrali, le nostre evidenze hanno mostrato una tendenza del modello verso una policy di tipo `treat-all`.

Questa discrepanza è stata attribuita a due fattori principali:

- **Bias di selezione residuo:** La superiorità della strategia `treat-all` nel test set è probabilmente frutto di un bias che la pipeline non è riuscita a eradicare completamente. È ipotizzabile che i pazienti selezionati dal personale medico per ricevere diuretici precoci fossero fisiologicamente pronti a tollerarli (avendo già superato la fase di instabilità), rendendo il trattamento apparentemente benefico su larga scala.
- **Effetto trainante dell'alto rischio:** La stratificazione per bin di rischio ha rivelato che il guadagno clinico è stato massivo quasi esclusivamente nei pazienti ad alto rischio (verosimilmente quelli con edema polmonare o forte congestione). Questo beneficio estremo ha matematicamente oscurato gli effetti nulli o leggermente dannosi riscontrati nei bin a basso rischio, trascinando il valore della policy verso la somministrazione universale.

In sintesi, nonostante `diur_v1` sia stato il migliore in termini di qualità del segnale e bilanciamento rispetto ai casi precedenti, la conclusione di "trattare tutti" va letta come un'indicazione di personalizzazione mancata.

Il modello ha intercettato un segnale di efficacia nei più gravi, ma non ha posseduto la risoluzione necessaria per proteggere i pazienti a basso rischio da un potenziale overtreatment. Pertanto, il dataset presenta criticità strutturali che ne limitano l'utilità in scenari di inferenza causale avanzata.

Di seguito, in Tabella 2.1, un riassunto dei dataset individuati su MIMIC-IV.

| Dataset ID | N (tot) | Trattamento          | Mortalità | Risultato Principale e Analisi del Bias                                                                                                      |
|------------|---------|----------------------|-----------|----------------------------------------------------------------------------------------------------------------------------------------------|
| vaso_v0    | 65.281  | Vasopressori precoci | 10.64%    | <b>Bias di indicazione forte:</b> Il CATE suggerisce di non trattare nessuno perché associa il farmaco alla gravità intrinseca (shock).      |
| rbc_v1_f   | 15.612  | Trasfusione RBC      | 13.15%    | <b>Violazione Positivity:</b> Separazione quasi totale del PS ( $10^{-7}$ vs 0.99). Inferenza inaffidabile per assenza di overlap.           |
| sepsis_v2  | 23.637  | Corticosteroidi      | 14.89%    | <b>Segnale di danno:</b> PS molto basso (schacciato). Il modello predice danno per il 99% dei pazienti; policy ottimale: <b>treat-none</b> . |
| diur_v1    | 6.216   | Diuretici precoci    | 9.76%     | <b>Miglior candidato:</b> Buon overlap. Policy <b>treat-all</b> guidata dal forte beneficio nel sottogruppo ad alto rischio (congestione).   |

Tabella 2.1: Riepilogo delle caratteristiche e dei risultati dei dataset estratti da MIMIC-IV.

## 2.6 AIDS Clinical Trials Group (ACTG 175)

### 2.6.1 Validazione su Dataset RCT

Dopo aver analizzato dataset osservazionali estratti da MIMIC-IV, la pipeline è stata testata sul dataset ACTG 175, un trial clinico randomizzato [2]. L'obiettivo è stato verificare il comportamento dei modelli CATE in un contesto dove il confounding è assente per design, fornendo una "ground truth" metodologica, la pipeline di analisi usata è la stessa per MIMIC-IV, mentre per la data selection si è proceduto a un controllo specifico.

#### Razionale Clinico e Letteratura

Nello studio ACTG 175 è stata testata l'efficacia di diversi regimi terapeutici in pazienti con HIV (conta CD4 tra 200 e 500 cellule/mm<sup>3</sup>). I risultati originali pubblicati dimostrano che la terapia combinata (Zidovudina + Didanosina o Zalcitabina) o la monoterapia con Didanosina siano superiori alla sola Zidovudina (AZT) nel rallentare la progressione della malattia e ridurre la mortalità.

In questo esperimento, abbiamo trattato il dataset come un problema di inferenza causale binaria (trattamento superiore vs. standard), cercando di identificare se esistesse un valore aggiunto nella personalizzazione rispetto alla raccomandazione universale emersa dal trial originale.

## Setup del Campione

Il dataset comprende 2.139 pazienti, con un set di valutazione di 321 individui.

- Feature: 20 variabili numeriche (età, peso, conta CD4 iniziale, ecc.).
- Outcome: Fallimento terapeutico (label).
- Propensity Score: Come previsto in un RCT, la distribuzione del PS (Figura 2.5) è risultata ben centrata (mediana 0.78) e priva di estremismi patologici, confermando un ottimo supporto empirico.

Un dato interessante è emerso dall'analisi della SMD. Essendo un RCT, il bilanciamento iniziale era già ottimale (SMD media 0.072). L'applicazione di pesi IPTW e ATO ha paradossalmente peggiorato il bilanciamento (SMD post  $> 0.1$ ). Questo fenomeno è spiegabile con l'introduzione di rumore campionario dovuto al re-weighting su un campione di test numericamente limitato ( $N=321$ ), dove la randomizzazione aveva già svolto il suo compito.




Figura 2.5: Distribuzione PS Score tra i gruppi di trattamento e controllo.

## Stima dell'Effetto

Le stime dell'effetto medio (ATE) sono risultate coerenti con la letteratura (segno negativo, ovvero riduzione della failure), ma con una forte instabilità statistica:


- L'intervallo di confidenza bootstrap ha incluso lo zero per tutti i modelli, con una varianza elevata per lo stimatore AIPW.
- Il DR-Learner ha rilevato una forte eterogeneità (Deviazione Standard del CATE pari a 0.64), ma l'analisi critica suggerisce che tale dispersione sia in gran parte rumore statistico. Quando il segnale medio è debole o il campione è piccolo, i modelli CATE tendono a sovrastimare l'eterogeneità individuale.

## Analisi delle Policy e Calibrazione

Il confronto tra le diverse strategie decisionali ha confermato la solidità delle conclusioni del trial originale:

- **Dominanza treat-all:** La policy personalizzata basata sul segno del CATE ( $\tau < 0$ ) non è riuscita a superare la strategia uniforme di trattare tutti i pazienti (**treat-all**), sebbene in generale sempre migliore di **treat-none**.
- **Soglie di Intervento:** L'ottimizzazione tramite Threshold Curve ha mostrato che il valore massimo della policy si ottiene trattando circa l'85% dei pazienti. Questo risultato si avvicina molto alla strategia universale, confermando che il trattamento ha un beneficio così diffuso che la selezione dei pazienti porta un guadagno marginale o nullo.
- **Calibrazione:** Nonostante un'ottima correlazione ordinale (il ranking dei pazienti era corretto), la corrispondenza con l'effetto reale per bin è stata solo moderata.

Una nota importante: la classificazione per bin di rischio evidenzia, similmente alle evidenze trovate in **diur\_v1**, che i soggetti a basso rischio hanno un outcome contrastante con la main policy individuata dai modelli e in parziale contrasto con le evidenze del paper originale, evidenziando un limite strutturale della pipeline nell'identificazione di alcuni sottogruppi con outcome diverso, come evidenziato in Figura 2.6.



(a) Outcome per bin di rischio in confronto tra **treat-none** e policy individuata dal modello.

(b) Curva di threshold per la policy evidenza come trattare tutti sia individuata come la policy migliore.

Figura 2.6: Incongruenze tra l'outcome per bin di rischio (a) e la policy generica in (b).

### 2.6.2 Confronto Modelli: DR-Learner vs. BCAUSS

È stato effettuato un confronto diretto tra le stime del DR-Learner e del modello BCAUSS. I due approcci sono risultati quasi totalmente discordanti (correlazione 0.034).

- BCAUSS ha prodotto stime molto più conservative e concentrate attorno allo zero (83% di beneficio previsto, ma di entità minima).
- Questa divergenza strutturale indica che, in presenza di campioni piccoli e assenza di forte eterogeneità clinica, la scelta del modello domina il risultato, rendendo la personalizzazione instabile.

### 2.6.3 Conclusione Operativa e Sintesi Critica




Figura 2.7: Analisi dei benefici per Bin di Rischio - ACTG 175

Il dataset `aids_v1` è servito come "stress test" per la pipeline e ground truth per testing sulle successive parti del progetto. Per quanto riguarda la robustezza della pipeline di creazione e analisi dei dataset:

- **Validazione della Policy Globale:** I risultati hanno supportato la decisione clinica emersa nel paper originale di Hammer et al.: il trattamento è globalmente efficace e la strategia più sicura resta l'alta copertura (`treat-all`).
- **Limiti personalizzazione:** Il tentativo di personalizzare la terapia tramite CATE in questo dataset non sembra portare vantaggi decisionali netti, sebbene la stratificazione degli outcome per rischio indichi un subset di pazienti il cui outcome potrebbe migliorare con trattamento di controllo, come visibile in Figura 2.7. Tuttavia, l'alto rapporto segnale/rumore (SNR) ha dimostrato che, se un trattamento funziona bene per quasi tutti, l'algoritmo di apprendimento eterogeneo rischia di inseguire fluttuazioni casuali dei dati piuttosto che reali differenze biologiche.
- **Qualità dataset:** Sebbene sia un RCT "pulito", la dimensione ridotta del test set ha limitato la capacità della pipeline di produrre intervalli di confidenza stretti, confermando che per la medicina di precisione basata su CATE sono necessari volumi di dati significativamente più ampi (come quelli cercati, seppur con bias, in MIMIC-IV).

---

# CAPITOLO 3

---

## BIAS TOOLS

### 3.1 Bias Tools: Introduzione

Al fine di costruire un ambiente sperimentale adatto alla valutazione di metodi di inferenza causale e, in particolare, di procedure di stima del *Conditional Average Treatment Effect* (CATE), è stato sviluppato un insieme di strumenti dedicati alla trasformazione di un dataset derivato da trial randomizzato in una versione progressivamente più simile ad un dataset osservazionale. L'obiettivo non è stato quello di alterare arbitrariamente i dati, ma di introdurre in modo controllato e riproducibile specifiche fonti di distorsione che, nella pratica applicativa, compromettono la validità delle stime causali.

In questo contesto sono stati progettati e implementati due moduli distinti, ciascuno dedicato ad una diversa classe di bias:

- un modulo di **selection bias**, finalizzato a simulare una popolazione osservata non rappresentativa del campione iniziale;
- un modulo di **confounding bias**, finalizzato a rimuovere la randomizzazione del trattamento e a costruire un meccanismo di assegnazione dipendente dalle covariate baseline.

La separazione tra i due strumenti è stata una scelta metodologica intenzionale. Selection bias e confounding bias rappresentano infatti due fenomeni causalmente distinti e con effetti differenti sull'inferenza:

- il **selection bias** agisce modificando la composizione del campione osservato, alterando quindi la distribuzione delle covariate e, indirettamente, anche quella di trattamento e outcome;
- il **confounding bias** agisce invece sul meccanismo di assegnazione del trattamento, generando dipendenza tra trattamento e covariate prognostiche.

Dal punto di vista operativo, i due moduli sono stati implementati come strumenti indipendenti ma componibili, in modo da permettere sia analisi isolate dei singoli effetti, sia

la costruzione di pipeline più articolate. In particolare, il workflow sperimentale adottato prevede la possibilità di partire da un dataset RCT, applicare dapprima una procedura di selezione sulle unità osservate e, successivamente, introdurre un meccanismo artificiale di assegnazione del trattamento basato su propensity score. Questa scelta consente di ottenere un dataset finale che preserva la struttura clinica del dataset originario, ma che incorpora alcune delle principali criticità tipiche dei dati osservazionali.

Entrambi i tool sono stati codificati secondo una architettura composta da moduli separati per:

- configurazione;
- input/output;
- preprocessing;
- logica di bias injection;
- diagnostica e reportistica.

Questa organizzazione ha infatti permesso di separare chiaramente:

1. le trasformazioni strutturali del dataset;
2. i passaggi strettamente necessari alla simulazione del bias;
3. le procedure di validazione e diagnostica;
4. la generazione di output utilizzabili nelle fasi successive dell'esperimento.

Ogni tool produce infatti, oltre al dataset trasformato, anche informazioni diagnostiche utili a quantificare l'effetto del bias introdotto. Tra queste rientrano, a seconda del modulo considerato, misure di variazione nella composizione del campione, probabilità individuali di inclusione, indicatori di assegnazione artificiale del trattamento, metriche di bilanciamento tra gruppi e report riassuntivi in formato strutturato.

Inoltre, accanto ai tool di bias injection, è stato previsto anche un passaggio di pulizia e armonizzazione finale, finalizzato a ricondurre i dataset trasformati ad una struttura compatibile con il dataset originale, preservando le informazioni necessarie alle analisi comparative successive.

Nelle sezioni che seguono vengono descritti in dettaglio i due strumenti sviluppati, le procedure di pulizia applicate ai dataset trasformati e i principali risultati ottenuti in termini di alterazione controllata delle proprietà del campione e del meccanismo di trattamento.

## 3.2 Selection Bias Tool

### 3.2.1 Definizione del problema

Nel contesto di questo lavoro, con il termine *selection bias* si intende una distorsione introdotta dal fatto che il campione osservato non coincide con la popolazione iniziale di riferimento. Più precisamente, il dataset finale non è ottenuto tramite una semplice

sottoestrazione casuale delle unità, ma tramite un processo di inclusione dipendente dalle caratteristiche baseline dei soggetti. In questo scenario, alcune tipologie di pazienti risultano sistematicamente più probabili da osservare rispetto ad altre, con la conseguenza che il campione finale presenta una distribuzione delle covariate differente rispetto al campione originario.

Dal punto di vista causale, il fenomeno che si è scelto di simulare è una forma di **selection bias pre-treatment**, in cui la probabilità di inclusione dipende esclusivamente da variabili osservate prima del trattamento. Indicando con  $X$  il vettore delle covariate baseline e con  $S \in \{0, 1\}$  una variabile binaria di selezione, il meccanismo implementato può essere descritto come

$$P(S = 1 \mid X),$$

dove  $S = 1$  indica che l'unità viene mantenuta nel dataset finale. Questa formulazione corrisponde ad un meccanismo di selezione sulla popolazione osservata, e non ad una selezione post-treatment o outcome-dependent.

È importante sottolineare che, in questa impostazione, il tool non modifica direttamente né il trattamento né l'outcome, né altera i valori originari delle covariate cliniche. L'effetto del modulo è invece quello di modificare la composizione del campione, rendendo il dataset osservato non rappresentativo del dataset di partenza. Di conseguenza, anche variabili non esplicitamente incluse nella funzione di selezione, come il trattamento o l'outcome, possono subire variazioni marginali nella loro distribuzione, in quanto correlate alle covariate su cui la selezione viene effettuata.

### 3.2.2 Scelte metodologiche della soluzione

La progettazione del Selection Bias Tool è stata guidata da due obiettivi principali:

1. introdurre una forma di distorsione coerente con un problema di non rappresentatività del campione;
2. mantenere un meccanismo sufficientemente controllabile, interpretabile e riproducibile, in modo da poter essere utilizzato in maniera sistematica all'interno del workflow sperimentale.

#### Selezione pre-treatment su covariate baseline

La prima scelta metodologica rilevante è stata quella di modellare il selection bias come funzione delle sole covariate baseline. Questa decisione permette di interpretare il meccanismo di selezione come un processo di inclusione nel dataset osservato dipendente da caratteristiche cliniche o strutturali già presenti prima dell'assegnazione del trattamento.

Questa scelta presenta diversi vantaggi:

- garantisce una narrativa causale più chiara;

- consente di separare in modo netto il problema della composizione del campione dal problema dell'assegnazione del trattamento;
- permette di comporre successivamente il selection bias con altri moduli, come quello di confounding, mantenendo la leggibilità dell'intero workflow.

### Scelta di un modello probabilistico di inclusione

Una seconda scelta centrale è stata quella di evitare una selezione deterministica o una rimozione casuale uniforme delle righe. Una semplice eliminazione casuale di una quota del dataset, infatti, ridurrebbe la numerosità campionaria ma non introdurrebbe un vero bias di selezione strutturato. Per ottenere invece una distorsione interpretabile e controllata, è stato adottato un modello probabilistico di inclusione.

Per ciascuna unità  $i$  si definisce un punteggio lineare:

$$\eta_i = \sum_{j=1}^p w_j X_{ij}^* + \delta T_i,$$

dove:

- $X_{ij}^*$  rappresenta la  $j$ -esima covariata baseline utilizzata nella selezione;
- $w_j$  è il peso associato alla covariata  $j$ ;
- $\delta$  è l'eventuale peso associato al trattamento, utilizzabile in modalità opzionale;
- nel caso principale implementato in questo lavoro, il trattamento non viene incluso, per cui  $\delta = 0$ .

Il punteggio lineare viene poi trasformato in una probabilità di inclusione tramite una funzione logistica:

$$p_i = \sigma(\alpha + \lambda \eta_i)$$

dove  $\sigma(\cdot)$  è la sigmoide,  $\alpha$  è un'intercetta e  $\lambda$  è un coefficiente globale di intensità della selezione.

Infine, l'indicatore di selezione viene campionato come:

$$S_i \sim \text{Bernoulli}(p_i).$$

Questo schema consente di modellare il selection bias come un processo stocastico ma non uniforme, in cui la probabilità di rimanere nel dataset finale dipende in modo sistematico dal profilo del soggetto.

### Separazione tra struttura del bias e intensità della selezione

Una scelta progettuale particolarmente importante è stata la separazione tra:

- **struttura del bias**, determinata dai pesi associati alle covariate;

- **intensità media della selezione**, determinata dal target di inclusione complessivo.

La struttura del bias stabilisce quali soggetti risultano favoriti o penalizzati dal meccanismo di selezione. Ad esempio, un peso positivo per una covariata come `karnof` rende più probabile l'inclusione di pazienti con performance status migliore, mentre un peso negativo su `symptom` riduce la probabilità di inclusione dei pazienti sintomatici.

L'intensità media della selezione viene invece controllata tramite un parametro di *target inclusion rate*, che definisce la quota media di soggetti che si intende mantenere nel campione finale. Per ottenere tale risultato, l'intercetta  $\alpha$  non viene fissata manualmente, ma calibrata numericamente in modo che la media delle probabilità individuali soddisfi approssimativamente la condizione

$$\frac{1}{n} \sum_{i=1}^n p_i \approx r,$$

dove  $r$  è il tasso medio di inclusione desiderato. In questo modo, il tool consente di modificare in maniera indipendente la forma del bias e la severità complessiva della selezione.

### Diagnostica e reportistica

L'introduzione di bias simulati non è utile se non è accompagnata da una quantificazione esplicita del loro effetto. Per questo motivo, il Selection Bias Tool non produce solo un dataset selezionato, ma anche un insieme di misure diagnostiche che consentono di verificare:

- il tasso effettivo di inclusione ottenuto;
- la distribuzione delle probabilità individuali di selezione;
- la variazione nella distribuzione del trattamento e dell'outcome;
- lo sbilanciamento indotto sulle covariate baseline.

Per la valutazione dello spostamento del campione vengono utilizzate in particolare misure di *standardized mean difference* (SMD) tra campione eleggibile e campione selezionato. Questo consente di quantificare in maniera standardizzata il grado di alterazione introdotto dalla selezione.

### 3.2.3 Implementazione del tool

Il Selection Bias Tool è stato implementato come modulo autonomo all'interno della cartella `tool/selection_bias/`, con una struttura esplicitamente modulare. L'organizzazione del codice è stata pensata per separare le principali responsabilità del tool in componenti indipendenti e riutilizzabili:

- `config/`: definizione dei parametri di esecuzione e dei valori di default;
- `io/`: caricamento e salvataggio di dataset e report;

- **preprocessing/**: validazione dell'input, gestione dei missing e scaling delle covariate;
- **selection/**: costruzione del punteggio di selezione, calibrazione dell'intercetta, calcolo delle probabilità e campionamento dell'indicatore di inclusione;
- **reports/**: produzione delle metriche di riepilogo e dei report JSON;
- **run\_selection\_bias.py**: entry point CLI del tool.

### Fase di validazione e preprocessing

Il tool riceve in input un dataset tabellare e un insieme di covariate da utilizzare nel modello di selezione. Prima di eseguire la simulazione, il dataset viene sottoposto a una fase di validazione che controlla:

- presenza delle colonne richieste;
- assenza di dataframe vuoti;
- assenza di problemi strutturali sulle covariate utilizzate.

Successivamente viene applicata una policy di gestione dei valori mancanti. Nel caso adottato negli esperimenti principali, è stata utilizzata una policy di tipo **drop**, che elimina dal campione eleggibile le unità con valori mancanti nelle covariate utilizzate per la selezione. Questa scelta consente di mantenere chiara la distinzione tra perdita di unità dovuta a missingness e perdita di unità dovuta al selection bias simulato.

Le covariate numeriche vengono poi standardizzate, mentre le covariate binarie vengono mantenute nella loro forma originaria. La standardizzazione permette di rendere comparabili le scale delle variabili e di interpretare in modo più stabile i pesi assegnati nel modello di selezione.

### Costruzione del meccanismo di selezione

Una volta ottenute le covariate preprocessate, il tool costruisce il punteggio lineare di selezione a partire dai pesi specificati in configurazione. Le feature effettivamente utilizzate dal modello possono quindi includere:

- covariate continue standardizzate;
- covariate binarie non scalate;
- opzionalmente il trattamento, se richiesto (di default: false).

L'intercetta del modello viene calibrata numericamente tramite una procedura di bisezione, in modo da ottenere il tasso medio di inclusione desiderato. Questa fase è cruciale perché consente di controllare con precisione la numerosità attesa del dataset finale senza perdere la struttura differenziale della selezione tra soggetti.

Una volta calcolate le probabilità individuali di inclusione, il tool campiona l'indicatore di selezione tramite una distribuzione Bernoulli. Il dataset annotato risultante contiene quindi sia le colonne originali sia le colonne tecniche aggiuntive necessarie a descrivere il processo:

- covariate scalate;
- `selection_linear_score`;
- `selection_probability`;
- `selection_indicator`.

Il dataset finale selezionato viene ottenuto filtrando le sole righe con `selection_indicator = 1`.

## Output prodotti

Il tool produce due tipi principali di output:

1. un dataset trasformato, corrispondente al campione finale selezionato;
2. un report strutturato in formato JSON contenente informazioni diagnostiche sul processo di selezione.

Inoltre, a seconda della configurazione, può essere salvato anche un dataset annotato completo, contenente tutte le unità eleggibili e le colonne tecniche intermedie.

Il report finale include tipicamente:

- configurazione del run;
- numero di righe in input, eleggibili e selezionate;
- tasso medio di inclusione desiderato e tasso realizzato;
- statistiche del punteggio lineare e delle probabilità di selezione;
- riepilogo della gestione dei missing;
- statistiche di scaling;
- bilanciamento delle covariate tra campione eleggibile e campione selezionato.

## Proprietà del dataset risultante

È importante evidenziare che il dataset finale prodotto dal Selection Bias Tool non costituisce ancora un dataset osservazionale nel senso pieno del termine. Il modulo, infatti, altera la rappresentatività del campione, ma non modifica ancora il meccanismo di assegnazione del trattamento. Il risultato è quindi un campione selezionato, ma non ancora confuso.

In particolare, dopo l'applicazione del Selection Bias Tool:

- il numero di unità osservate si riduce;
- la distribuzione delle covariate baseline cambia in funzione del meccanismo di selezione;
- la distribuzione marginale di trattamento e outcome può cambiare indirettamente;

- il trattamento mantiene tuttavia la propria natura originaria, non essendo ancora stato riassegnato tramite il modulo di confounding bias.

Per questa ragione, il Selection Bias Tool rappresenta il primo stadio del processo di trasformazione del dataset, mentre l'introduzione di un vero meccanismo osservazionale di assegnazione del trattamento viene demandata al modulo successivo di confounding bias.

## 3.3 Confounding Bias Tool

### 3.3.1 Definizione del problema

Nel contesto dell'inferenza causale, il *confounding bias* si verifica quando il trattamento non è assegnato indipendentemente dalle covariate baseline, ma risulta associato a variabili che influenzano anche l'outcome. In tale situazione, il confronto diretto tra soggetti trattati e non trattati non riflette più soltanto l'effetto del trattamento, ma incorpora anche differenze strutturali preesistenti tra i gruppi.

Formalmente, in un trial randomizzato ideale, il trattamento  $T$  è assegnato in modo indipendente da  $X$ , dove  $X$  rappresenta il vettore delle covariate baseline. In un dataset osservazionale, invece, la probabilità di ricevere il trattamento dipende tipicamente proprio da  $X$ :

$$P(T = 1 \mid X).$$

Il problema affrontato dal Confounding Bias Tool è precisamente la simulazione di questo passaggio: partire da un dataset con trattamento originariamente randomizzato e costruire una nuova variabile di trattamento che risulti dipendente dalle covariate baseline, in modo da ottenere un dataset pseudo-osservazionale.

In questa impostazione, il tool non modifica le covariate cliniche né rigenera l'outcome. L'intervento del modulo consiste esclusivamente nella costruzione di un nuovo meccanismo di assegnazione del trattamento, che sostituisce la randomizzazione originale con una policy artificiale dipendente da  $X$ . Il risultato è un dataset in cui trattamento e covariate risultano sbilanciati, riproducendo una delle caratteristiche centrali dei dati osservazionali.

### 3.3.2 Scelte metodologiche della soluzione

La progettazione del Confounding Bias Tool è stata guidata da un obiettivo specifico: trasformare il trattamento originariamente randomizzato in un trattamento *pseudo-osservazionale*, preservando però il più possibile la struttura clinica del dataset di partenza.

La prima scelta metodologica è stata quella di non alterare i valori delle covariate baseline e di non rigenerare l'outcome. Le variabili cliniche osservate vengono mantenute inva-

riate, così come l'outcome disponibile nel dataset. Il bias viene introdotto unicamente modificando la regola di assegnazione del trattamento.

Questa scelta ha due vantaggi principali: in primo luogo, consente di isolare il fenomeno di interesse: il dataset finale differisce da quello originario non perché i pazienti siano stati artificialmente riscritti, ma perché il trattamento non segue più una procedura randomizzata. In secondo luogo, tale impostazione permette di interpretare il modulo come un vero strumento di simulazione del *treatment assignment mechanism*, cioè del processo attraverso cui, in un contesto osservazionale, certi pazienti risultano più probabili da trattare rispetto ad altri.

### Uso di un propensity score artificiale

Per introdurre il confounding bias si è scelto di costruire un **propensity score artificiale**, cioè una probabilità sintetica di ricevere il trattamento basata sulle covariate baseline. L'idea è definire una funzione del tipo

$$P(T_{\text{obs}} = 1 \mid X),$$

dove  $T_{\text{obs}}$  rappresenta il nuovo trattamento pseudo-osservazionale.

Operativamente, per ciascun soggetto  $i$  viene calcolato un predittore lineare

$$\eta_i = \alpha + \sum_{j=1}^p \beta_j X_{ij}^*,$$

dove:

- $X_{ij}^*$  sono le covariate baseline standardizzate;
- $\beta_j$  sono i coefficienti associati a ciascuna covariata;
- $\alpha$  è un termine di intercetta.

Il predittore lineare viene trasformato tramite una sigmoide in una probabilità individuale di trattamento:

$$e_i = \sigma(\eta_i),$$

che costituisce il propensity score artificiale del soggetto  $i$ .

Tale quantità viene poi utilizzata per campionare un nuovo trattamento binario:

$$T_{\text{obs},i} \sim \text{Bernoulli}(e_i).$$

In questo modo il trattamento risultante non è più indipendente dalle covariate, ma viene assegnato in modo sistematico a seconda del profilo del paziente.

Un'altra possibile scelta metodologica sarebbe stata assegnare il trattamento in modo deterministico, ad esempio trattando tutti i soggetti con propensity score superiore ad una certa soglia. Questa scelta è stata evitata perché troppo rigida e poco realistica.

L'uso di una variabile Bernoulliana consente invece di introdurre dipendenza tra trattamento e covariate senza rendere l'assegnazione completamente deterministica. A parità di profilo clinico, soggetti simili possono ancora ricevere trattamenti diversi, ma in modo non uniforme. Questo rispecchia meglio il comportamento dei dati osservazionali reali, in cui la decisione terapeutica è influenzata dalle covariate ma non è perfettamente deterministica.

### Clipping del propensity score

Nel processo di costruzione del trattamento artificiale è stata introdotta una fase di *clipping* del propensity score. Dopo il passaggio attraverso la sigmoide, i valori di  $e_i$  vengono limitati a un intervallo prefissato:

$$e_i^{\text{clip}} = \min(\max(e_i, c_{\min}), c_{\max}),$$

dove  $0 < c_{\min} < c_{\max} < 1$ .

Questa scelta è stata adottata per evitare probabilità troppo vicine a 0 o a 1, che produrrebbero assegnazioni quasi deterministiche e ridurrebbero in modo eccessivo l'overlap tra gruppi trattati e non trattati. Dal punto di vista sperimentale, il clipping permette di introdurre un confounding anche forte, ma mantenendo un dataset ancora analizzabile e coerente con una struttura osservazionale ragionevole.

### Standardizzare le covariate nel modello di assegnazione

Prima della costruzione del propensity score artificiale, le covariate utilizzate nel modello vengono standardizzate. Questa scelta è motivata dal fatto che le variabili cliniche possono trovarsi su scale molto diverse tra loro: età, peso, count immunologici e indicatori binari non sono direttamente confrontabili in termini numerici.

La standardizzazione consente di:

- rendere comparabili i contributi delle diverse covariate nel predittore lineare;
- evitare che variabili con range numerico più ampio dominino artificialmente il modello;
- rendere più interpretabile la direzione relativa dei coefficienti associati alle covariate.

Il risultato è una costruzione del trattamento artificiale più stabile e più facilmente controllabile.

### Separazione tra trattamento originario e trattamento pseudo-osservazionale

Una scelta importante del tool è stata quella di non sovrascrivere immediatamente il trattamento originario, ma di generare una nuova colonna di trattamento. Nel dataset trasformato coesistono quindi:

- la colonna del trattamento originario, che riflette la struttura del dataset di partenza;

- una nuova colonna di trattamento artificiale, che rappresenta l'assegnazione pseudo-osservazionale.

Questa scelta è utile sia sul piano metodologico sia su quello operativo. Da un lato permette di tracciare esplicitamente la trasformazione effettuata; dall'altro consente confronti diretti tra assegnazione originaria e assegnazione artificiale.

### Diagnostica esplicita del confounding introdotto

Come nel caso del Selection Bias Tool, anche qui l'obiettivo non è soltanto trasformare il dataset, ma misurare in modo esplicito l'intensità del bias introdotto. Per questa ragione il modulo produce diagnostiche dedicate a descrivere quanto il nuovo trattamento dipenda dalle covariate baseline e quanto i gruppi trattati e non trattati risultino sbilanciati.

In particolare, il tool valuta:

- la distribuzione del propensity score artificiale;
- la prevalenza del trattamento originario e di quello nuovo;
- la capacità delle covariate di predire il nuovo trattamento, tramite AUC;
- il bilanciamento tra gruppi trattati e non trattati tramite standardized mean differences.

Queste misure consentono di verificare che il dataset risultante non sia più compatibile con una randomizzazione ideale e che il confounding sia stato effettivamente introdotto.

### 3.3.3 Implementazione del tool

Il Confounding Bias Tool è stato implementato come modulo autonomo nella cartella `tool/confounding_bias/`, secondo una struttura modulare analoga a quella adottata per il Selection Bias Tool. L'architettura del codice è articolata nei seguenti componenti:

- `config/`: definizione dei parametri di esecuzione e delle configurazioni del tool;
- `io/`: caricamento e salvataggio dei dataset e dei report;
- `preprocessing/`: validazione delle colonne richieste, gestione dei missing e standardizzazione delle covariate;
- `propensity/`: costruzione del propensity score artificiale, campionamento del nuovo trattamento ed evaluation metrics;
- `reports/`: costruzione del report finale e delle metriche di bilanciamento;
- `run_confounding_bias.py`: entry point CLI del tool.

#### Fase di preprocessing

Il tool riceve in input un dataset tabellare, un insieme di covariate baseline e i nomi delle colonne corrispondenti a outcome, trattamento originario e nuovo trattamento. La fase iniziale effettua controlli di validità sull'input, assicurando che le colonne necessarie siano presenti e che il dataset sia utilizzabile.

Successivamente viene costruito il dataset di lavoro per il modello di confounding. Le righe con valori mancanti nelle covariate richieste, nell'outcome o nel trattamento originario vengono rimosse, mentre il resto della struttura del dataset viene preservato per consentire analisi successive. Le covariate indicate in configurazione vengono poi standardizzate e trasformate nel vettore  $X^*$  utilizzato per la costruzione del propensity score artificiale.

### Costruzione del propensity score artificiale

All'interno del modulo `propensity/` il tool definisce una policy artificiale di assegnazione del trattamento tramite un insieme di coefficienti associati alle covariate baseline. Questi coefficienti vengono utilizzati per costruire il predittore lineare del modello logistico, che viene poi trasformato in propensity score tramite sigmoide.

Il propensity score viene salvato sia nella sua forma grezza sia nella sua forma clippata. In particolare, il dataset trasformato include tipicamente colonne come:

- `ps_artificial_raw`;
- `ps_artificial`;
- `treat_obs`.

La colonna `treat_obs` è ottenuta campionando il nuovo trattamento secondo una distribuzione Bernoulliana parametrizzata dal propensity score clippato.

### Valutazione della strength dell'assegnazione

Dopo la generazione del nuovo trattamento, il tool misura la forza dell'associazione tra covariate baseline e trattamento artificiale. A questo scopo viene addestrato un classificatore logistico che predice il trattamento pseudo-osservazionale a partire dalle covariate standardizzate, e viene calcolata l'area sotto la curva ROC (AUC).

Questa quantità non coincide con il propensity score stesso, ma costituisce una misura riassuntiva della capacità complessiva di  $X$  di spiegare il nuovo trattamento. Valori elevati di AUC indicano che il trattamento non è più quasi-randomizzato, ma fortemente dipendente dalle covariate, cioè che il confounding introdotto è sostanziale.

### Bilanciamento tra gruppi trattati e non trattati

Il tool produce inoltre una tabella di bilanciamento che confronta i gruppi definiti da `treat_obs = 1` e `treat_obs = 0`. Per ciascuna covariata vengono riportate:

- media nel gruppo trattato;
- media nel gruppo di controllo;
- differenza tra le medie;
- standardized mean difference.

La balance table viene ordinata secondo il valore assoluto della standardized mean difference, in modo da evidenziare immediatamente le covariate su cui lo sbilanciamento

è maggiore. Questa diagnostica permette di verificare che il dataset risultante presenti effettivamente le caratteristiche attese di un campione osservazionale confuso.

## Output prodotti

Il Confounding Bias Tool produce:

1. un dataset trasformato che mantiene la struttura clinica di partenza e aggiunge le colonne relative al propensity score e al nuovo trattamento;
2. un report JSON contenente le principali statistiche del processo di trasformazione.

Il report include tipicamente:

- numero di righe del dataset originale e finale;
- covariate utilizzate nel modello di assegnazione;
- coefficienti utilizzati nella policy artificiale;
- prevalenza del trattamento originario e del nuovo trattamento;
- riepilogo della distribuzione del propensity score;
- AUC di predizione del nuovo trattamento a partire da  $X$ ;
- principali shift di bilanciamento tra trattati e controlli.

## Proprietà del dataset risultante

Il dataset prodotto dal Confounding Bias Tool mantiene le osservazioni del campione in input, ma modifica il meccanismo di trattamento. Rispetto al dataset originario o al dataset già selezionato in ingresso:

- il numero di righe rimane invariato, salvo eventuali esclusioni dovute ai missing nelle colonne richieste;
- le covariate baseline non vengono alterate;
- l'outcome osservato non viene rigenerato;
- viene invece introdotta una nuova colonna di trattamento pseudo-osservazionale dipendente dalle covariate.

Dal punto di vista causale, il dataset risultante non è più compatibile con una struttura randomizzata del trattamento. I gruppi trattati e non trattati risultano infatti sbilanciati su covariate prognostiche baseline, e questo rende il dataset adatto a simulare in modo controllato una componente di confounding tipica dei dati osservazionali.

Nel workflow complessivo del progetto, questo modulo rappresenta quindi il secondo stadio della trasformazione del dataset: dopo aver eventualmente alterato la composizione del campione tramite selection bias, esso introduce una dipendenza strutturale tra trattamento e covariate, completando la costruzione del dataset pseudo-osservazionale utilizzato negli esperimenti successivi.

## 3.4 Cleaning e Dataset Harmonization

### 3.4.1 Motivazione del passaggio di cleaning

L'applicazione sequenziale dei moduli di selection bias e confounding bias produce dataset intermedi che, pur essendo metodologicamente utili, non risultano immediatamente adatti alle fasi successive dell'analisi. In particolare, durante i passaggi di trasformazione vengono introdotte colonne tecniche necessarie al funzionamento interno dei tool e alla produzione di diagnostiche, come ad esempio probabilità di inclusione, indicatori di selezione, covariate standardizzate, propensity score artificiali e nuove variabili di trattamento.

Queste informazioni sono fondamentali per verificare la correttezza del processo di bias injection, ma non coincidono con lo schema del dataset originale e non sono necessariamente appropriate come input finale per i Large Language Models. Nel contesto del presente lavoro, tale esigenza è particolarmente rilevante perché il dataset finale deve poter essere confrontato con il dataset iniziale mantenendo coerenza strutturale, tracciabilità delle unità e compatibilità con il processo di predizione successivamente affidato al modello linguistico.

Per questa ragione è stato introdotto un ulteriore strumento dedicato alla finalizzazione e armonizzazione del dataset, implementato nello script `clean_data.py`. Il suo scopo non è introdurre un nuovo bias, ma ricondurre il dataset trasformato ad una forma coerente con quella originaria, preservando esclusivamente le informazioni necessarie all'analisi finale.

### 3.4.2 Metodologia della soluzione

Il problema principale affrontato dal tool di cleaning è il seguente: dopo la fase di bias injection, il dataset risultante contiene sia variabili originarie sia variabili tecniche aggiuntive, e può inoltre includere più di una colonna relativa al trattamento. Tale situazione, se non esplicitamente gestita, rende difficile:

- confrontare il dataset trasformato con il dataset RCT di partenza;
- mantenere una struttura di input omogenea per i modelli successivi;
- interpretare correttamente quale colonna di trattamento debba essere considerata la variabile finale di esposizione.

Per risolvere questo problema, si è scelto di adottare un criterio di armonizzazione *schema-driven*, in cui il dataset originale viene trattato come riferimento strutturale. In altre parole, la struttura finale del dataset non viene definita manualmente elencando le colonne da mantenere o da rimuovere, ma viene ricavata direttamente dal dataset iniziale, considerato come *reference schema*.

Questa scelta presenta diversi vantaggi:

- evita di hardcodare nel codice un elenco di colonne tecniche da eliminare;
- rende il processo più robusto a eventuali modifiche future dei tool intermedi;

- garantisce che il dataset finale abbia esattamente lo stesso insieme di colonne del dataset di partenza, nello stesso ordine;
- consente di mantenere automaticamente eventuali colonne originarie non coinvolte direttamente nei moduli di bias injection, ma comunque utili per analisi successive.

### Sostituzione del trattamento originario con quello pseudo-osservazionale

Una scelta particolarmente importante riguarda la gestione del trattamento. Dopo il modulo di confounding bias, il dataset contiene tipicamente sia il trattamento originario sia il nuovo trattamento pseudo-osservazionale generato artificialmente. Tuttavia, ai fini del confronto tra dataset iniziale e dataset finale, non è opportuno mantenere due colonne semanticamente concorrenti per la stessa variabile.

Si è quindi deciso di adottare la seguente convenzione:

1. la colonna del trattamento originario viene mantenuta come nome canonico nello schema finale;
2. i suoi valori vengono sostituiti con quelli della colonna di trattamento pseudo-osservazionale;
3. la colonna tecnica contenente il trattamento artificiale viene rimossa dal dataset finale.

Questa soluzione consente di ottenere un dataset armonizzato in cui il significato causale del trattamento è stato aggiornato, ma la struttura complessiva del dataset resta compatibile con quella originaria. In termini pratici, il dataset finale conserva la colonna `treat` come colonna di esposizione, ma i valori presenti al suo interno corrispondono al trattamento osservazionale artificiale prodotto dal tool di confounding bias.

### Rimozione delle colonne tecniche aggiuntive

Durante le fasi di trasformazione vengono prodotte diverse colonne tecniche, tra cui ad esempio:

- covariate standardizzate;
- score lineari di selezione;
- probabilità di inclusione;
- indicatori binari di selezione;
- propensity score artificiali grezzi o clippati;
- colonne ausiliarie di trattamento osservazionale.

Queste colonne sono estremamente utili per debugging, validazione, audit e reportistica, ma non devono necessariamente comparire nel dataset finale utilizzato nelle analisi comparative o come input per i modelli di stima del CATE. Per questa ragione, il tool di cleaning rimuove sistematicamente tutte le colonne che non appartengono allo schema del dataset di riferimento, mantenendo soltanto le colonne originarie.

### Preservazione degli identificativi

Nel workflow sperimentale adottato, la preservazione degli identificativi delle unità è un requisito essenziale. Poiché il progetto richiede il confronto tra predizioni effettuate sul dataset originario e su versioni trasformate dello stesso dataset, è necessario che le osservazioni rimaste nel campione finale mantengano un collegamento esplicito con i soggetti di partenza.

Per questo motivo, il processo di armonizzazione non genera nuovi identificativi, ma preserva la colonna identificativa presente nel dataset originario, trattandola come parte integrante dello schema di riferimento. In questo modo, il dataset finale mantiene la tracciabilità delle unità e consente confronti paired o join espliciti tra dataset RCT e dataset osservazionali trasformati.

#### 3.4.3 Implementazione del tool di armonizzazione

Il processo di armonizzazione finale è stato implementato nello script autonomo `clean_data.py`, progettato con l'obiettivo di ricondurre il dataset trasformato a una struttura pienamente compatibile con quella del dataset originario.

Il tool di armonizzazione è stato costruito attorno all'idea di utilizzare il dataset iniziale come riferimento strutturale. In pratica, il dataset originale viene caricato non per recuperare i valori, ma per estrarne lo schema: l'insieme delle colonne presenti e il loro ordine. Questo schema viene poi utilizzato come guida per ricostruire il dataset finale a partire dalla versione trasformata, che contiene tutte le modifiche introdotte dai tool precedenti.

Il primo passaggio eseguito da `clean_data.py` consiste quindi nel caricamento di due dataset distinti: da un lato il dataset di riferimento, cioè il dataset originario da cui si vuole ereditare la struttura finale; dall'altro il dataset trasformato, prodotto dopo i passaggi di bias injection. Il dataset di riferimento viene trattato come sorgente dello schema canonico, mentre il dataset trasformato costituisce la base informativa su cui il tool opera per costruire l'output finale.

Una volta caricati i due dataset, il tool esegue una verifica di coerenza strutturale. Questa fase ha lo scopo di garantire che il dataset trasformato contenga tutte le informazioni necessarie per ricostruire correttamente il dataset finale armonizzato. In particolare, viene verificato che le colonne presenti nel dataset di riferimento siano disponibili anche nel dataset trasformato, oppure che siano comunque presenti le variabili necessarie per derivarle correttamente. Viene inoltre controllata la presenza delle colonne di trattamento rilevanti, cioè la colonna del trattamento originario e quella del trattamento pseudo-osservazionale generata dal modulo di confounding bias. Questa fase di validazione è essenziale, perché impedisce di produrre dataset finali parziali, inconsistenti o strutturalmente non confrontabili con il dataset iniziale.

Il cuore dell'armonizzazione è rappresentato dalla gestione della variabile di trattamento. Dopo il passaggio di confounding bias, il dataset trasformato contiene infatti sia il trattamento originale sia una nuova colonna che rappresenta il trattamento osservazionale artificiale. Ai fini dell'analisi finale, tuttavia, mantenere entrambe le colonne sarebbe ridondante e rischierebbe di introdurre ambiguità interpretative. Per questa ragione, il tool

adotta una convenzione precisa: la colonna del trattamento originario viene mantenuta come nome canonico nello schema finale, ma i suoi valori vengono sostituiti con quelli del trattamento pseudo-osservazionale. In termini operativi, il passaggio effettuato è il seguente:

```
treat ← treat_obs.
```

Questa scelta consente di ottenere un dataset finale in cui il significato causale del trattamento è stato aggiornato, ma la struttura della tabella rimane coerente con quella del dataset originario. In altre parole, il dataset finale continua ad avere la stessa colonna di trattamento prevista dallo schema di partenza, ma il contenuto di tale colonna rappresenta ormai l'assegnazione pseudo-osservazionale costruita artificialmente.

Dopo la sostituzione del trattamento, il tool procede alla ricostruzione vera e propria del dataset finale. Questa fase consiste nel mantenere esclusivamente le colonne presenti nel dataset di riferimento, rispettandone esattamente l'ordine originale. Tutte le colonne aggiuntive introdotte durante le fasi di bias injection vengono quindi rimosse automaticamente. In questo modo non è necessario elencare manualmente le variabili tecniche da eliminare: è sufficiente utilizzare come criterio di selezione lo schema del dataset iniziale. Il risultato è un dataset armonizzato che conserva le osservazioni sopravvissute ai passaggi di selezione, mantiene gli identificativi originali, preserva tutte le variabili cliniche presenti nel dataset di partenza e utilizza come trattamento finale la versione pseudo-osservazionale generata artificialmente.

### Output del tool

Il tool produce come output principale un dataset finale pulito, pronto per essere utilizzato nelle analisi successive. Opzionalmente, può inoltre produrre un piccolo report strutturato contenente metadati sul processo di finalizzazione, quali:

- numero di righe del dataset di riferimento;
- numero di righe del dataset trasformato;
- numero di righe del dataset finale;
- colonna di trattamento originaria;
- colonna di trattamento osservazionale utilizzata per la sostituzione;
- elenco delle colonne aggiuntive rimosse.

### Ruolo del tool nel workflow complessivo

Dal punto di vista del workflow complessivo, `clean_data.py` rappresenta l'ultimo passaggio della pipeline di costruzione del dataset pseudo-osservazionale. Dopo che selection bias e confounding bias hanno introdotto le distorsioni desiderate, il tool di cleaning riconduce il dataset a una forma strutturalmente comparabile con il dataset di partenza.

## 3.5 Risultati ottenuti

In questa sezione vengono presentati i principali risultati ottenuti dall'applicazione sequenziale dei tool descritti nelle sezioni precedenti. L'obiettivo non è soltanto mostrare che i moduli sono stati eseguiti correttamente, ma anche verificare in modo quantitativo che ciascun passaggio abbia prodotto l'effetto atteso sulle proprietà del dataset.

L'analisi dei risultati viene articolata secondo i tre momenti fondamentali del workflow:

1. il dataset ottenuto dopo l'applicazione del **Selection Bias Tool**;
2. il dataset ottenuto dopo l'applicazione del **Confounding Bias Tool** sul campione già selezionato;
3. il dataset finale prodotto dal tool di **cleaning e armonizzazione**, confrontato con il dataset originario di partenza.

Questa organizzazione consente di isolare il contributo di ciascun modulo e di valutare separatamente i diversi effetti introdotti lungo la pipeline. Nel primo passaggio, l'attenzione è rivolta alla modifica della composizione del campione osservato; nel secondo passaggio, al cambiamento del meccanismo di assegnazione del trattamento; nel terzo, alla verifica della coerenza strutturale del dataset finale e della sua compatibilità con lo schema originario.

Dal punto di vista metodologico, i risultati vengono discussi lungo tre dimensioni principali.

In primo luogo, si valuta la **variazione della composizione del campione**, osservando il numero di unità mantenute, la distribuzione delle covariate baseline e le eventuali variazioni marginali di trattamento e outcome. Questa parte è particolarmente rilevante per il Selection Bias Tool, il cui effetto principale consiste proprio nell'alterare la rappresentatività del campione osservato.

In secondo luogo, si analizza la **dipendenza del trattamento dalle covariate baseline**, verificando quanto il nuovo trattamento pseudo-osservazionale risulti spiegabile da  $X$ . A questo scopo vengono utilizzate sia misure riassuntive del propensity score artificiale, sia metriche di strength dell'assegnazione, come l'AUC di predizione del nuovo trattamento a partire dalle covariate, sia indicatori di sbilanciamento tra gruppi trattati e di controllo.

Infine, si esamina la **struttura del dataset finale**, verificando che il processo di armonizzazione abbia prodotto un output coerente con il dataset di partenza in termini di schema, identificativi e semantica delle variabili, pur preservando le distorsioni introdotte dai moduli di bias injection.

È importante sottolineare che i risultati riportati in questa sezione non devono essere interpretati come una semplice descrizione di output tecnici, ma come una verifica del fatto che il dataset finale possieda effettivamente le proprietà desiderate per gli esperimenti successivi. In particolare, il dataset risultante deve soddisfare due requisiti fondamentali:

- essere sufficientemente diverso dal dataset RCT iniziale da poter essere considerato una versione pseudo-osservazionale plausibile;

- mantenere una struttura sufficientemente coerente con quella del dataset originario da consentire confronti diretti e utilizzo controllato nelle fasi successive dello studio.

Nelle sottosezioni che seguono, i risultati vengono quindi presentati in ordine di pipeline, partendo dagli effetti del selection bias, passando poi all'introduzione del confounding bias e concludendo con la caratterizzazione del dataset finale armonizzato.

### 3.5.1 Contesto sperimentale: dataset ACTG175

I risultati presentati in questa sezione sono ottenuti a partire dal dataset ACTG175, utilizzato come base sperimentale per la costruzione del dataset pseudo-osservazionale. ACTG175 è un trial clinico randomizzato su pazienti affetti da HIV, ed è stato scelto proprio perché fornisce un contesto iniziale metodologicamente pulito: il trattamento, infatti, è assegnato in maniera randomizzata e il confounding risulta assente per design.

Questa proprietà è particolarmente importante nel presente lavoro, poiché consente di osservare in modo controllato l'effetto dei tool sviluppati. Il dataset iniziale può infatti essere interpretato come una baseline di riferimento rispetto alla quale misurare le distorsioni introdotte artificialmente lungo la pipeline. In altri termini, selection bias e confounding bias non vengono qui stimati a partire da un dataset già osservazionale, ma vengono costruiti in modo esplicito e sequenziale su un campione originariamente randomizzato.

Dal punto di vista operativo, il dataset ACTG175 utilizzato negli esperimenti contiene 2139 osservazioni ed è caratterizzato da un insieme di covariate baseline clinicamente rilevanti, tra cui età, peso corporeo, performance status, trattamenti precedenti e indicatori immunologici come la conta CD4. L'outcome considerato è la variabile binaria `label`, mentre il trattamento originario è rappresentato dalla colonna `treat`.

L'uso di ACTG175 nel presente capitolo assume quindi una funzione specifica: non quella di validare nuovamente la pipeline CATE nel contesto RCT, ma quella di fornire il punto di partenza strutturale e causale su cui vengono applicati i tool di bias injection. I risultati mostrati nelle sezioni successive devono essere letti precisamente in questa prospettiva: l'obiettivo è verificare come un dataset inizialmente randomizzato venga progressivamente trasformato in una versione pseudo-osservazionale attraverso la modifica della composizione del campione e, successivamente, del meccanismo di assegnazione del trattamento.

### 3.5.2 Risultati del Selection Bias Tool

Il Selection Bias Tool è stato applicato al dataset ACTG175, con un insieme di otto covariate baseline selezionate per il meccanismo di inclusione: `age`, `wtkg`, `karnof`, `oprior`, `preanti`, `strat`, `cd40` e `symptom`. La colonna di trattamento considerata nel dataset di input è `treat`, mentre la colonna di outcome è `label`. La policy di gestione dei missing è stata fissata a `drop`, il *target inclusion rate* è stato impostato a 0.8, il parametro di intensità globale della selezione a 1.0 e il seme casuale a 42. Il trattamento non è stato incluso nel modello di selezione (`include_treatment_in_selection = false`), e il vettore dei pesi utilizzato per le covariate è stato il seguente:

$$w = \begin{cases} \text{age} = 0.8, \\ \text{wtkg} = -0.2, \\ \text{karnof} = 1.0, \\ \text{oprior} = 0.4, \\ \text{preanti} = 0.3, \\ \text{strat} = -0.1, \\ \text{cd40} = 0.9, \\ \text{symptom} = -0.5. \end{cases}$$

### Analisi dell'applicazione del tool

Il dataset di input contiene 2139 osservazioni e 25 colonne. La fase di validazione e preprocessing non ha evidenziato criticità strutturali: il numero totale di valori mancanti è nullo, il numero di righe con almeno un valore mancante è pari a zero, e la policy **drop** non ha comportato alcuna perdita di unità. Di conseguenza, il campione eleggibile coincide con il campione iniziale, con 2139 osservazioni. Nel report diagnostico, questo comportamento è descritto in modo esplicito: per tutte le covariate coinvolte nel meccanismo di selezione, il numero di missing è pari a zero sia prima sia dopo il preprocessing, e il numero di righe eliminate è nullo. Questo implica che la riduzione di numerosità osservata nel dataset finale è interamente attribuibile al meccanismo di selection bias simulato, e non a operazioni di pulizia o imputazione.

Dopo il preprocessing, il dataset annotato presenta 34 colonne. L'aumento rispetto alle 25 colonne iniziali è dovuto all'aggiunta di colonne tecniche prodotte dal tool, che comprendono sia variabili standardizzate sia quantità intermedie del modello di selezione. In particolare, sei covariate continue sono state standardizzate: **age**, **wtkg**, **karnof**, **preanti**, **strat** e **cd40**. Le due covariate binarie **oprior** e **symptom** sono invece state lasciate nella forma originaria e riportate nel report come **skipped\_binary\_columns**. Le statistiche di scaling mostrano, per ciascuna covariata continua, il valore medio e la deviazione standard utilizzati per la trasformazione. In particolare:

$$\begin{aligned} \mu_{\text{age}} &= 35.2482, & \sigma_{\text{age}} &= 8.7070, \\ \mu_{\text{wtkg}} &= 75.1253, & \sigma_{\text{wtkg}} &= 13.2601, \\ \mu_{\text{karnof}} &= 95.4465, & \sigma_{\text{karnof}} &= 5.8996, \\ \mu_{\text{preanti}} &= 379.1758, & \sigma_{\text{preanti}} &= 468.5480, \\ \mu_{\text{strat}} &= 1.9799, & \sigma_{\text{strat}} &= 0.8988, \\ \mu_{\text{cd40}} &= 350.5012, & \sigma_{\text{cd40}} &= 118.5461. \end{aligned}$$

Il modello di selezione è stato quindi costruito utilizzando come feature effettive:

(**age\_scaled**, **wtkg\_scaled**, **karnof\_scaled**,  
**oprior**, **preanti\_scaled**, **strat\_scaled**, **cd40\_scaled**, **symptom**).

Il trattamento non è stato incluso nel predittore lineare, come confermato dal report (**treatment\_included** = **false**, **treatment\_column** = **null**, **treatment\_weight**

= 0.0). Il punteggio lineare di selezione risultante (`selection_linear_score`) presenta media pari a  $-0.0777$ , deviazione standard pari a  $1.5902$ , minimo pari a  $-6.6251$  e massimo pari a  $5.7566$ . Questa distribuzione indica un'ampia eterogeneità individuale nella propensione alla selezione, che si traduce in probabilità di inclusione fortemente differenziate tra i soggetti.

La calibrazione dell'intercetta è stata eseguita con procedura di bisezione, imponendo un target inclusion rate pari a 0.8. Il report mostra che la procedura ha richiesto 29 iterazioni e ha identificato un valore di intercetta pari a  $2.02948$ , ottenendo una probabilità media teorica di inclusione pari a  $0.7999999959$ , quindi praticamente coincidente con il target desiderato. Questo passaggio è particolarmente importante, perché consente di distinguere tra la forma della selezione, determinata dai pesi sulle covariate, e la sua severità media, fissata invece dal target di inclusione.

Le probabilità individuali di inclusione (`selection_probability`) mostrano una distribuzione con media  $0.8000$ , deviazione standard  $0.2077$ , minimo  $0.00999$  e massimo  $0.99958$ . Questo dato conferma che il meccanismo di selezione non corrisponde a una semplice rimozione uniforme di una quota del dataset, ma a un processo strutturato in cui soggetti con profili baseline differenti ricevono probabilità molto diverse di rimanere nel campione osservato.

Il campionamento finale dell'indicatore di selezione (`selection_indicator`), produce 1736 osservazioni selezionate su 2139 eleggibili, con un tasso realizzato di inclusione pari a  $0.8116$ . La lieve discrepanza rispetto al target teorico di 0.8 è interamente spiegabile con la natura stocastica del campionamento Bernoulliano. Dal punto di vista sperimentale, questo comportamento è atteso: il target viene imposto sulla media delle probabilità, non direttamente sul numero finale di unità osservate.

### Analisi degli effetti del tool di selezione

L'effetto del tool sulla composizione del campione è evidente anche confrontando il dataset iniziale con il dataset selezionato. La prevalenza del trattamento nel campione di input è pari a  $0.7513$  (1607 soggetti trattati su 2139), mentre nel campione selezionato scende a  $0.7414$  (1287 soggetti trattati su 1736). Poiché il trattamento non entra esplicitamente nel modello di selezione, questa variazione deve essere interpretata come un effetto indiretto della modifica della distribuzione di  $X$ : selezionando una sottopopolazione con caratteristiche baseline differenti, viene alterata marginalmente anche la distribuzione del trattamento originario.

La modifica della composizione del campione può essere quantificata tramite la tabella di bilanciamento tra campione eleggibile e campione selezionato. Per ciascuna covariata, il report riporta la media prima e dopo la selezione, la differenza tra le medie e la standardized mean difference (SMD). Le variazioni più rilevanti si osservano per `karnof` e `cd40`. In particolare, `karnof` passa da una media di  $95.4465$  a una media di  $96.3652$ , con differenza pari a  $0.9187$  e  $SMD = 0.1644$ . La covariata `cd40` passa invece da  $350.5012$  a  $365.6653$ , con differenza pari a  $15.1642$  e  $SMD = 0.1276$ . Si osservano inoltre variazioni più moderate per `age` (da  $35.2482$  a  $35.8191$ ,  $SMD = 0.0650$ ) e per `symptom` (da  $0.1730$  a  $0.1509$ ,  $SMD = -0.0599$ ). Gli altri spostamenti risultano più contenuti: `preanti` presenta  $SMD = 0.0349$ , `strat`  $= 0.0070$ , `wtkg`  $= 0.0055$  e `oprior`  $= -0.0126$ .

Questi risultati sono coerenti con il vettore dei pesi utilizzato nel modello di selezione. Il peso positivo assegnato a `karnof` e `cd40` favorisce infatti l'inclusione di soggetti con valori più elevati di performance status e conta CD4, mentre il peso negativo su `symptom` riduce la probabilità di osservare pazienti sintomatici. Anche l'effetto positivo su `age` contribuisce a spostare il campione finale verso soggetti mediamente più anziani. Nel complesso, il tool produce quindi una popolazione osservata clinicamente differente dal campione iniziale, ma in una direzione perfettamente coerente con le scelte parametriche definite in configurazione.

La sintesi finale del bilanciamento conferma che il selection bias introdotto è presente ma di intensità moderata. Il numero di covariate con SMD valido è pari a 8, la media dei valori assoluti di SMD è pari a 0.0596 e il massimo valore assoluto osservato è 0.1644. Questi numeri indicano che il campione finale non è una semplice sottoestrazione casuale del dataset RCT, ma una sottopopolazione selezionata in maniera non uniforme. Allo stesso tempo, l'entità dello sbilanciamento rimane sufficientemente contenuta da produrre un dataset plausibile e interpretabile, utile come primo stadio della trasformazione verso un contesto pseudo-osservazionale.

Nel complesso, il report diagnostico mostra che il Selection Bias Tool ha raggiunto l'obiettivo previsto: introdurre una perdita selettiva di unità osservate, modificare la distribuzione delle covariate baseline in modo controllato, alterare indirettamente la distribuzione marginale del trattamento e produrre un dataset finale che non può più essere considerato rappresentativo del campione randomizzato iniziale, pur senza aver ancora modificato il meccanismo di assegnazione del trattamento.

### 3.5.3 Risultati del Confounding Bias Tool

Il Confounding Bias Tool è stato applicato al dataset risultante dal passaggio di selection bias, costituito da 1736 osservazioni. Poiché il preprocessing non ha comportato ulteriori eliminazioni, il numero di righe del dataset finale coincide con quello del dataset in input al modulo, pari a 1736 unità. In questo caso, il tool non agisce sulla composizione del campione, ma esclusivamente sul meccanismo di assegnazione del trattamento, costruendo una nuova variabile di esposizione pseudo-osservazionale a partire da un propensity score artificiale.

Le covariate utilizzate per il modello di assegnazione sono le stesse già impiegate nei passaggi precedenti, ossia `age`, `wtkg`, `karnof`, `oprior`, `preanti`, `strat`, `cd40` e `symptom`. L'outcome considerato è `label`, la colonna del trattamento originario è `treat`, mentre il nuovo trattamento artificiale generato dal modulo è salvato in `treat_obs`. La colonna contenente il propensity score artificiale è `ps_artificial`.

Il vettore dei coefficienti utilizzato nella policy artificiale di assegnazione del trattamento è il seguente:

$$\beta = \begin{cases} \text{age} = 0.35, \\ \text{wtkg} = -0.2, \\ \text{karnof} = -0.6, \\ \text{oprior} = 0.55, \\ \text{preanti} = 0.45, \\ \text{strat} = 0.4, \\ \text{cd40} = -1.0, \\ \text{symptom} = 0.5. \end{cases}$$

La struttura di questi coefficienti definisce in maniera esplicita la direzione del confounding introdotto. In particolare, il nuovo trattamento tende a essere assegnato più frequentemente a soggetti con età maggiore, presenza di terapia precedente, maggiore esposizione pregressa (**preanti**), valori più elevati di **strat** e presenza di sintomi, mentre tende a essere assegnato meno frequentemente a soggetti con conta **cd40** più elevata, maggiore peso corporeo e miglior performance status (**karnof**). In altri termini, il meccanismo artificiale costruito dal tool favorisce il trattamento in soggetti clinicamente più gravi o comunque caratterizzati da un profilo di rischio meno favorevole.

### Analisi dei risultati ottenuti dal tool di confondimento

Un primo risultato rilevante riguarda la variazione della prevalenza del trattamento. Nel dataset in input al modulo, cioè nel campione già selezionato, la prevalenza del trattamento originario **treat** è pari a 0.7414. Dopo il passaggio di confounding bias, la prevalenza del nuovo trattamento pseudo-osservazionale **treat\_obs** scende a 0.4902. Questo indica che il tool non si limita a perturbare marginalmente il trattamento esistente, ma costruisce una nuova assegnazione con distribuzione sostanzialmente diversa, coerente con il nuovo meccanismo dipendente dalle covariate.

Il propensity score artificiale prodotto dal modello presenta una distribuzione chiaramente compatibile con il clipping imposto in configurazione. Il valore minimo osservato è pari a 0.05, il primo percentile è anch'esso pari a 0.05, il quinto percentile è pari a 0.0598, la mediana è pari a 0.4699, il novantacinquesimo percentile è pari a 0.95, il novantanovesimo percentile è ancora pari a 0.95, il massimo osservato è pari a 0.95 e il valore medio complessivo risulta pari a 0.4871. Questi numeri mostrano in modo molto chiaro l'effetto della procedura di clipping: le probabilità individuali di trattamento vengono esplicitamente limitate all'intervallo [0.05, 0.95], evitando assegnazioni quasi deterministiche e preservando un livello minimo di overlap tra gruppi trattati e non trattati.

Dal punto di vista metodologico, questo aspetto è importante per almeno due ragioni. In primo luogo, consente di introdurre un confounding forte senza distruggere completamente il supporto comune tra i gruppi. In secondo luogo, produce un dataset più realistico dal punto di vista osservazionale, in cui il trattamento è fortemente associato alle covariate ma non in modo perfettamente deterministico.

La forza complessiva del nuovo meccanismo di assegnazione è quantificata dalla metrica **assignment\_auc\_predicting\_new\_treatment\_from\_X**, che assume valore pari a 0.8452. Questa AUC misura la capacità delle covariate baseline di predire il nuovo trattamento

pseudo-osservazionale. Un valore così elevato indica che il trattamento artificiale non è più compatibile con una assegnazione quasi randomizzata, ma risulta fortemente spiegabile a partire da  $X$ . Dal punto di vista sperimentale, questo è il segnale principale che il confounding bias è stato effettivamente introdotto: il trattamento finale è divenuto strutturalmente dipendente dalle caratteristiche baseline dei pazienti.

Una conferma ancora più esplicita dell'introduzione del confounding emerge dalla tabella di bilanciamento tra soggetti con `treat_obs = 1` e soggetti con `treat_obs = 0`. Le differenze tra i due gruppi, quantificate tramite standardized mean difference, risultano molto più marcate rispetto a quanto osservato dopo il solo passaggio di selection bias. La covariata maggiormente sbilanciata è `cd40`, con media pari a 319.2150 nel gruppo trattato e 410.3311 nel gruppo di controllo, differenza di  $-91.1160$  e  $SMD = -0.8285$ . Questo risultato è perfettamente coerente con il peso fortemente negativo assegnato a `cd40`, che rende meno probabile il trattamento nei soggetti con valori elevati di questa variabile.

La seconda covariata più sbilanciata è `strat`, che passa da una media pari a 1.6870 nei controlli a 2.2973 nei trattati, con differenza 0.6103 e  $SMD = 0.7164$ . Anche `preanti` mostra uno sbilanciamento molto marcato, con media 554.6663 nel gruppo trattato contro 243.0169 nel gruppo di controllo, differenza 311.6493 e  $SMD = 0.6775$ . La covariata `karnof` risulta invece più elevata nel gruppo di controllo, con una differenza di  $-2.2976$  e  $SMD = -0.4465$ , coerente con il peso negativo assegnato a questa variabile nel modello di trattamento.

Ulteriori shift rilevanti si osservano per `age`, con media pari a 37.7180 nei trattati e 33.9932 nei controlli ( $SMD = 0.4299$ ), e per `symptom`, con prevalenza pari a 0.2268 nei trattati e 0.0780 nei controlli ( $SMD = 0.4230$ ). Anche `oprior` risulta sbilanciata, con  $SMD = 0.2761$ , mentre `wtkg` mostra uno shift più contenuto ma comunque visibile, con  $SMD = -0.1561$ .

Nel complesso, la tabella di bilanciamento descrive due gruppi di pazienti chiaramente distinti sul piano clinico. I soggetti assegnati al trattamento pseudo-osservazionale risultano mediamente più anziani, più sintomatici, con maggiore esposizione terapeutica pregressa, valori più elevati di `strat` e valori più bassi di `cd40` e `karnof`. Il quadro complessivo è quindi pienamente coerente con la finalità del tool: generare un trattamento che venga assegnato preferenzialmente a soggetti con caratteristiche baseline prognosticamente diverse da quelle dei controlli.

Dal punto di vista causale, questo risultato è centrale. Mentre nel dataset RCT iniziale il trattamento era assegnato per randomizzazione e quindi non dipendeva strutturalmente dalle covariate, nel dataset ottenuto dopo il Confounding Bias Tool la nuova variabile `treat_obs` risulta fortemente dipendente da  $X$ . I gruppi trattati e non trattati non sono più comparabili in modo diretto, poiché differiscono in maniera sostanziale su covariate che sono anche clinicamente rilevanti per l'outcome. Il dataset finale acquisisce quindi una proprietà tipica dei dati osservazionali: il trattamento è informativo rispetto al profilo baseline dei pazienti, e il confronto naïf tra trattati e controlli risulta distorto dalla presenza di confounding.

In sintesi, i risultati ottenuti mostrano che il Confounding Bias Tool ha raggiunto il proprio obiettivo in maniera netta. Il campione rimane invariato in termini di numerosità, ma il trattamento viene completamente riassegnato secondo una policy artificiale basata sulle covariate baseline. Il nuovo propensity score presenta una distribuzione coerente con

il clipping imposto, il trattamento risultante ha una prevalenza diversa rispetto a quello originario, l'AUC di predizione del trattamento a partire da  $X$  è elevata e la balance table evidenzia sbilanciamenti sostanziali tra gruppi. Il dataset prodotto dal tool può quindi essere interpretato come una versione pseudo-osservazionale del campione selezionato, in cui il meccanismo di assegnazione del trattamento non è più randomizzato, ma dipende in modo controllato e misurabile dalle caratteristiche baseline.

### 3.5.4 Risultati finali

L'ultimo passaggio del workflow è stato dedicato alla finalizzazione del dataset pseudo-osservazionale tramite il tool di cleaning e armonizzazione. Questa fase non introduce ulteriori modifiche causali, ma ha il compito di consolidare in un unico output finale gli effetti già prodotti dai moduli di selection bias e confounding bias, riportando al tempo stesso il dataset a una struttura pienamente compatibile con quella del campione originario.

Dal punto di vista sperimentale, questo passaggio è fondamentale per due ragioni. In primo luogo, consente di ottenere un dataset finale utilizzabile nelle analisi successive senza esporre colonne tecniche intermedie che descrivono il processo di bias injection ma non appartengono allo schema clinico di partenza. In secondo luogo, permette di costruire un output direttamente confrontabile con il dataset RCT iniziale, preservando la coerenza dello schema, l'ordine delle colonne e la tracciabilità delle unità sopravvissute ai passaggi precedenti.

Nelle sottosezioni seguenti vengono quindi discussi i risultati prodotti dal tool di armonizzazione, con particolare attenzione alla ricostruzione dello schema finale, alla gestione della variabile di trattamento e alle differenze strutturali tra dataset iniziale e dataset finale.

#### Armonizzazione strutturale del dataset finale

Il tool di armonizzazione è stato applicato utilizzando come *reference dataset* il dataset ACTG175 originario [vedi 2.6], composto da 2139 osservazioni, e come input trasformato il dataset ottenuto al termine dei passaggi di selection bias e confounding bias, costituito da 1736 osservazioni. Il dataset finale prodotto dal tool contiene a sua volta 1736 osservazioni. Questo risultato è coerente con la logica del workflow: il modulo di armonizzazione non altera la numerosità del campione trasformato, ma si limita a ricondurne la struttura allo schema del dataset iniziale.

Dal report di finalizzazione emerge che il dataset di riferimento definisce uno schema costituito da 25 colonne:

```
{id, time, trt, age, wtkg,
  hemo, homo, drugs, karnof,
  oprior, z30, zprior, preanti,
  race, gender, str2, strat,
  symptom, treat, offtrt, cd40,
  cd420, cd80, cd820, label}
```

Il dataset finale armonizzato viene quindi ricostruito imponendo esattamente questo insieme di colonne e il medesimo ordine. In questo modo, il tool garantisce che l'output finale sia strutturalmente omogeneo al dataset originario, indipendentemente dal numero e dalla natura delle colonne tecniche generate nei passaggi intermedi.

Un aspetto centrale del processo di armonizzazione riguarda la gestione della variabile di trattamento. Il dataset finale continua infatti ad avere una colonna denominata **treat**, come nel dataset RCT iniziale, ma il contenuto semantico di tale colonna è stato aggiornato: essa non rappresenta più l'assegnazione randomizzata originale, bensì il trattamento pseudo-osservazionale costruito artificialmente. In questo modo, il dataset finale conserva compatibilità strutturale con il dataset di partenza, pur incorporando il nuovo meccanismo di trattamento introdotto dal Confounding Bias Tool.

Il report documenta inoltre in maniera esplicita quali colonne tecniche siano state rimosse durante il processo di armonizzazione. L'elenco delle variabili eliminate comprende dodici colonne aggiuntive:

```
{age_scaled, wtkg_scaled, karnof_scaled,
  preanti_scaled, strat_scaled, cd40_scaled,
  selection_linear_score, selection_probability,
  selection_indicator, ps_artificial_raw,
  ps_artificial, treat_obs}
```

Questo insieme di colonne corrisponde esattamente alle quantità tecniche introdotte nei passaggi intermedi della pipeline. In particolare, vengono rimosse:

- le covariate standardizzate prodotte nei moduli di preprocessing;
- le variabili diagnostiche del Selection Bias Tool, ovvero punteggio lineare, probabilità di selezione e indicatore binario di inclusione;
- le variabili diagnostiche del Confounding Bias Tool, cioè propensity score artificiale grezzo, propensity score clippato e colonna esplicita del trattamento pseudo-osservazionale.

Questo risultato è rilevante perché consente di evitare leakage di informazioni tecniche verso le fasi successive dell'analisi e, allo stesso tempo, preserva tutte le variabili cliniche disponibili nel dataset iniziale.

Dal punto di vista strutturale, il dataset finale può quindi essere descritto come segue:

- mantiene la numerosità del campione trasformato, pari a 1736 osservazioni;
- preserva la colonna identificativa **id**, garantendo la tracciabilità delle unità;

- conserva tutte le 25 colonne presenti nel dataset RCT di partenza;
- utilizza come trattamento finale una versione pseudo-osservazionale della colonna `treat`;
- non espone più alcuna variabile tecnica relativa alla simulazione dei bias.

### Confronto finale tra dataset originario e dataset pseudo-osservazionale

Il confronto tra il dataset ACTG175 originario e il dataset finale ottenuto al termine dell'intera pipeline mostra che il processo di trasformazione ha preservato la compatibilità strutturale del dato, modificandone però in maniera sostanziale le proprietà statistiche e causali. Il dataset finale, infatti, mantiene lo stesso schema del trial di partenza, ma non ne conserva più né la rappresentatività campionaria né il meccanismo di assegnazione del trattamento.




Figura 3.1: Principali differenze nella numerosità del campione.

Una prima differenza evidente riguarda la numerosità del campione. Il dataset originario contiene 2139 osservazioni, mentre il dataset finale ne contiene 1736. Dal punto di vista interpretativo, il dataset finale non deve quindi essere letto come una semplice versione ridotta del dataset iniziale, bensì come una coorte selezionata in maniera non uniforme.

**Differenze nella composizione del campione.** Le trasformazioni più rilevanti si osservano nella distribuzione delle covariate baseline. Il confronto tra dataset originario e dataset finale, quantificato tramite *standardized mean difference*, evidenzia uno spostamento sistematico del profilo clinico della popolazione osservata.




Figura 3.2: Principali differenze nelle covariate baseline tra dataset originario e dataset finale, misurate tramite standardized mean difference.

Le covariate maggiormente alterate risultano essere `karnof` ( $SMD = 0.1644$ ), `cd40` ( $SMD = 0.1276$ ), `age` ( $SMD = 0.0650$ ) e `symptom` ( $SMD = -0.0599$ ). Questi risultati indicano che il dataset finale tende a contenere soggetti con performance status più elevato, conta CD4 più alta, età mediamente maggiore e minore presenza di sintomi rispetto al campione iniziale.

**Differenze nelle distribuzioni marginali di trattamento e outcome.** Le modifiche introdotte lungo la pipeline si riflettono anche nelle distribuzioni marginali delle variabili principali. Nel dataset originario, la prevalenza del trattamento è pari a 0.7513, mentre nel dataset finale si riduce a 0.4902. La prevalenza dell'outcome passa invece da 0.2436 a 0.2270. Queste differenze mostrano che il dataset finale non solo contiene una popolazione osservata differente, ma presenta anche una configurazione globale diversa rispetto al trial iniziale e nel caso del trattamento, il cambiamento è particolarmente rilevante.




Figura 3.3: Differenze nelle distribuzioni marginali di trattamento e outcome.

**Differenze nel meccanismo di trattamento.** L'alterazione più importante riguarda il passaggio da un trattamento assegnato per randomizzazione a un trattamento assegnato in funzione delle covariate baseline. Nel dataset RCT iniziale, il trattamento può essere considerato indipendente da  $X$  per design; nel dataset finale, al contrario, il trattamento risulta fortemente informativo rispetto al profilo clinico dei pazienti.

Questo emerge chiaramente sia dall'analisi quantitativa sia dalla rappresentazione grafica del propensity score. Nel dataset finale, i gruppi trattati e non trattati mostrano distribuzioni molto più separate rispetto al caso non biased, a indicare che la probabilità di trattamento è diventata funzione delle covariate baseline. In Figura 3.4 si può osservare la distribuzione del propensity score nel dataset finale, ed è quindi facile osservare quanto detto prima confrontando il precedente grafico con quello del dataset iniziale in Figura 2.5.



Figura 3.4: Distribuzione del propensity score nel dataset nel dataset finale pseudo-osservazionale.

La stessa conclusione emerge dall'analisi del bilanciamento tra trattati e controlli nel dataset finale. La struttura dello sbilanciamento è rappresentata in Figura 3.5, che evidenzia le covariate maggiormente responsabili della separazione tra trattati e controlli nel dataset finale.




Figura 3.5: Sbilanciamento tra trattati e controlli nel dataset finale, misurato tramite standardized mean difference rispetto al trattamento pseudo-osservazionale.

Le standardized mean differences rispetto al nuovo trattamento risultano molto elevate per diverse covariate, in particolare **cd40** ( $SMD = -0.8285$ ), **strat** ( $SMD = 0.7164$ ) e **preanti** ( $SMD = 0.6775$ ). Anche **karnof** ( $SMD = -0.4465$ ), **age** ( $SMD = 0.4299$ ) e

`symptom` ( $SMD = 0.4230$ ) mostrano uno sbilanciamento sostanziale. Questi valori sono incompatibili con una assegnazione randomizzata e costituiscono una evidenza diretta del confounding introdotto dal tool.

**Sintesi interpretativa.** Nel complesso, il dataset finale risultante dalla pipeline può essere interpretato come una versione pseudo-osservazionale del trial ACTG175. Esso conserva la struttura tabellare del dataset originario, inclusi schema, identificativi e semantica generale delle variabili cliniche, ma differisce da esso in tre aspetti sostanziali:

1. contiene una sottopopolazione selezionata e non più rappresentativa del campione RCT iniziale;
2. presenta distribuzioni marginali di trattamento e outcome differenti rispetto al dataset di partenza;
3. incorpora un meccanismo di assegnazione del trattamento non più randomizzato, ma dipendente in modo esplicito dalle covariate baseline.

Queste proprietà rendono il dataset finale adatto agli scopi del presente studio. Da un lato, esso resta sufficientemente compatibile con il dataset originario da consentire confronti controllati e tracciabilità delle osservazioni; dall'altro, è sufficientemente diverso da esso da costituire una vera approssimazione di un dataset osservazionale, su cui testare la robustezza dei metodi di stima del CATE e delle procedure basate su modelli linguistici.

---

# CAPITOLO 4

---

## LLM PREDICTION

### 4.1 Large Language Models

Nel presente lavoro sono stati utilizzati diversi Large Language Models (LLM) al fine di analizzarne il comportamento in un contesto di inferenza causale applicata a dati clinici strutturati. In particolare, l'analisi si è concentrata su tre modelli con caratteristiche eterogenee:

- **Gemma**, sviluppato da Google
- **LLaMA 3**, proposto da Meta
- **BioMistral**, un modello specializzato per il dominio biomedicale sviluppato dalla comunità di ricerca.

La scelta di utilizzare modelli differenti è motivata dalla necessità di valutare l'impatto della specializzazione del modello sul task considerato. In particolare, Gemma e LLaMA sono modelli general-purpose, addestrati su ampi corpora di testo eterogenei, mentre Mistral è stato progettato specificamente per applicazioni in ambito medico-clinico. Questa distinzione consente di osservare eventuali differenze nella capacità di interpretare le variabili cliniche e nella coerenza delle stime prodotte.

Un ulteriore aspetto considerato riguarda il compromesso tra prestazioni e costo computazionale. I modelli differiscono infatti per dimensione, requisiti di inferenza e gestione del contesto, fattori che influenzano sia la qualità dell'output sia la scalabilità della pipeline.

#### 4.1.1 Descrizione del dataset

L'analisi è stata condotta utilizzando il dataset **AIDS Clinical Trials Group Study 175 (ACTG 175)**, uno studio clinico randomizzato (Randomized Controlled Trial, RCT) ampiamente utilizzato nella letteratura di causal inference.

Il dataset contiene informazioni cliniche strutturate relative a pazienti affetti da HIV, incluse variabili demografiche, indicatori di stato di salute e informazioni sui trattamenti somministrati. La natura randomizzata dello studio garantisce, nel dominio RCT, l'assenza di bias di selezione, rendendolo un benchmark ideale per la valutazione di metodi causali.

Accanto al contesto RCT, è stato inoltre considerato un dominio osservazionale (OBS), in cui è presente bias di selezione, al fine di analizzare la capacità dei modelli di adattarsi a cambiamenti nella distribuzione dei dati.

### 4.1.2 Obiettivo del lavoro

L'obiettivo principale del lavoro consiste nella stima di una proxy della **Conditional Average Treatment Effect (CATE)**, definita come:

$$\text{CATE} = P(\text{mortality} \mid \text{treat} = 1) - P(\text{mortality} \mid \text{treat} = 0) \quad (4.1)$$

Il problema viene riformulato come un task di ragionamento guidato, in cui il modello deve inferire una stima numerica coerente a partire dalle informazioni fornite.

sente di isolare chiaramente le responsabilità di ciascun componente e di intervenire in modo mirato in caso di errori o comportamenti inattesi.

### 4.1.3 Architettura del sistema e progettazione dei prompt

La pipeline sviluppata per la stima della CATE tramite LLM è progettata secondo un approccio modulare, con l'obiettivo di garantire controllo sull'output, robustezza e facilità di debugging. Il flusso di esecuzione si articola nelle seguenti fasi:

1. caricamento e preprocessing del dataset;
2. suddivisione in batch (chunking);
3. generazione del prompt;
4. invocazione del modello;
5. parsing e validazione dell'output.

**Prompt generation** Il modulo di generazione del prompt ha il compito di costruire dinamicamente l'input fornito al modello, combinando:

- istruzioni di sistema;
- definizione esplicita del task;
- vincoli operativi;
- dati clinici del paziente o del batch.

Un aspetto cruciale è stato l'introduzione di **vincoli espliciti e stringenti**, tra cui:

- output esclusivamente in formato JSON
- assenza di testo descrittivo
- divieto di generare codice
- obbligo di produrre direttamente una stima numerica

Questi vincoli sono stati resi necessari per contrastare i comportamenti osservati nella fase iniziale (ad esempio risposte discorsive o generazione di codice).

Inoltre, la costruzione del prompt è stata progettata per essere **deterministica e riproducibile**, evitando variazioni non controllate che potessero influenzare l'output del modello.

**Evoluzione della progettazione dei prompt** In una fase iniziale è stato adottato un approccio monolitico, che ha evidenziato diverse criticità: instabilità dell'output, violazione dei vincoli, elevata variabilità tra modelli e aumento del costo computazionale.

Successivamente, si è passati a un approccio modulare, in cui le componenti del prompt (ruolo, task, vincoli e regole) sono state separate. Questo ha consentito di migliorare la controllabilità, la riusabilità e la coerenza delle risposte.

**Parsing e validazione** Il sistema implementa un meccanismo di **strict parsing**, che accetta esclusivamente output JSON validi conformi a uno schema predefinito. Output non conformi vengono scartati.

A questo si affianca un modulo di validazione semantica, che verifica:

- completezza degli ID;
- assenza di duplicati;
- validità numerica dei valori;
- rispetto di un range plausibile (es.  $[-1, 1]$ ).

L'interazione tra prompt, parsing e validazione costituisce un ciclo di controllo che riduce la natura probabilistica degli LLM, avvicinando il sistema a un comportamento più deterministico.

Inoltre, grazie alla natura completamente **deterministica della pipeline a valle del modello** e alla presenza di meccanismi di retry, il sistema garantisce che, in caso di output non valido, sia sempre possibile **rigenerare iterativamente risultati conformi sullo stesso input**, fino all'ottenimento di un output valido e consistente.

## 4.2 Analisi dei comportamenti dei modelli

Durante le fasi iniziali della sperimentazione sono emerse diverse criticità nel comportamento dei modelli, evidenziando limiti significativi nell'applicazione dei Large Language Models (LLM) a dati clinici strutturati caratterizzati da vincoli stringenti.

Una delle problematiche più rilevanti riguarda la difficoltà dei modelli nell'interpretare correttamente il formato strutturato dei dati in input. In numerosi casi, infatti, le feature cliniche venivano trattate come testo non strutturato, portando alla generazione di output incoerenti o non allineati al task richiesto. Questo si traduceva frequentemente in risposte che non riflettevano alcuna elaborazione effettiva delle variabili del paziente. Ad esempio, in alcuni casi BioMistral restituiva array JSON formalmente corretti, come `["id": 1498, "cate": -0.15, "id": 1499, "cate": 0.08, ...]`, accompagnati però da messaggi del tipo *“To calculate CATE, you need to have a target variable...”*, evidenziando una mancata comprensione operativa del task.

Un ulteriore fenomeno osservato riguarda la presenza di pattern ripetitivi nelle stime della CATE. I modelli tendevano infatti a restituire valori costanti o quasi costanti per input differenti. Nei log di LLaMA, ad esempio, sono ricorrenti sequenze come 0.08, -0.15, 0.08, -0.15 oppure 0.0, -0.0, 0.0, mentre in generale si osservano valori frequenti come 0.0, 0.5 e 0.12. Questo comportamento suggerisce una forma di collasso della variabilità dell'output: il modello, anziché applicare una logica condizionale basata sulle feature individuali, tende a convergere verso valori “sicuri” o statisticamente plausibili rispetto alla distribuzione appresa durante l'addestramento.

Differenze sostanziali emergono inoltre tra i modelli analizzati, evidenziando modalità distinte di fallimento rispetto al task:

- **BioMistral** mostra una marcata tendenza a interpretare il task come una richiesta procedurale, restituendo frammenti di codice (ad esempio in Python) per il calcolo della CATE anziché fornire direttamente una stima numerica. Nei log si osservano frequentemente snippet del tipo:

```
for id in [750, 751, ...]:
    treat_1 = df[df['id'] == id][df['treat'] == 1]['label'].mean()
    treat_0 = df[df['id'] == id][df['treat'] == 0]['label'].mean()
    cate.append({"id": id, "cate": treat_1 - treat_0})
```

Questo comportamento indica che il modello tende a descrivere la procedura di calcolo piuttosto che eseguire direttamente l'inferenza richiesta.

- **LLaMA** restituisce frequentemente sequenze di valori numerici altamente ripetitivi o nulli (ad esempio 0.0, -0.0, 0.08, -0.15), senza una differenziazione significativa tra individui. Ciò evidenzia un comportamento apparentemente deterministico ma non informativo rispetto alle feature cliniche, suggerendo l'utilizzo di pattern appresi piuttosto che una reale elaborazione dei dati.
- **Gemma**, infine, produce spesso risposte di tipo cautelativo o etico, suggerendo di consultare un medico o evitando di fornire una stima numerica. Questo comportamento è coerente con i meccanismi di safety alignment tipici dei modelli general-purpose, ma risulta incompatibile con i requisiti operativi del task.

Nel complesso, tali evidenze indicano che i modelli non sono naturalmente predisposti a eseguire task di inferenza strutturata in presenza di vincoli formali stringenti. Questo ha reso necessario intervenire sia sulla formulazione del prompt sia sulla progettazione della pipeline.

In particolare, si è reso necessario:

- rafforzare i vincoli espliciti nei prompt (ad esempio imponendo output esclusivamente numerici in formato JSON);
- ridurre le ambiguità nella definizione del task;
- guidare il modello verso un comportamento più deterministico e aderente all'obiettivo inferenziale.

Queste osservazioni hanno inoltre motivato la transizione verso una progettazione dei prompt più strutturata e modulare, descritta nella sezione precedente, con l'obiettivo di limitare comportamenti indesiderati e migliorare la consistenza delle risposte.

## 4.3 Confronto tra BCAUSS e LLM nella stima del CATE

L'obiettivo di questa analisi è confrontare le stime del Conditional Average Treatment Effect (CATE) prodotte dal modello causale BCAUSS con quelle generate da modelli basati su Large Language Models (Mistral, LLaMA e Gemma). Il confronto viene condotto in due contesti distinti: un dominio sperimentale (RCT), privo di bias di selezione, e un dominio osservazionale (OBS), caratterizzato dalla presenza di bias introdotti tramite il tool descritto in precedenza.

L'analisi considera la struttura delle distribuzioni del CATE, la granularità delle predizioni (dove il numero di valori unici corrisponde al numero di classi effettivamente predette) e la coerenza tra modelli in termini di errore e correlazione.

Per ciascun dominio, vengono riportate analisi descrittive, metriche di errore, correlazioni, e ispezioni visive tramite grafici di densità e Bland–Altman.

### 4.3.1 Dominio RCT

**Risultati descrittivi** Nel dominio RCT, BCAUSS restituisce una distribuzione del CATE ben strutturata, concentrata su valori negativi (media  $-0.0936$ ) e caratterizzata da una bassa varianza ( $0.0527$ ). La percentuale di effetti positivi è molto ridotta ( $2.8\%$ ), indicando un effetto del trattamento relativamente omogeneo.

Al contrario, i modelli LLM producono distribuzioni più disperse e centrate attorno allo zero, con una perdita significativa di granularità. Mentre BCAUSS genera valori quasi continui, gli LLM mostrano una marcata discretizzazione delle predizioni: Mistral e LLaMA concentrano le stime su un numero limitato di valori ricorrenti, mentre Gemma presenta un forte accumulo attorno allo zero. Questo comportamento suggerisce che gli LLM non approssimano una funzione continua del CATE, ma restituiscono livelli discreti che limitano la capacità di distinguere individui con effetti differenti.

Le statistiche descrittive confermano queste differenze: Mistral presenta una media leggermente positiva ( $0.0089$ ) e una dispersione moderata, con oltre la metà delle osservazioni positive ( $56.8\%$ ); LLaMA mostra una maggiore variabilità (deviazione standard  $0.1160$ ) e una media negativa ( $-0.0422$ ); Gemma risulta quasi centrata in zero ( $-0.0023$ ), con una distribuzione relativamente simmetrica.

| Modello | Media   | Std    | Min     | Max    | % CATE > 0 |
|---------|---------|--------|---------|--------|------------|
| BCAUSS  | -0.0936 | 0.0527 | -0.1968 | 0.0574 | 2.8%       |
| Mistral | 0.0089  | 0.0781 | -0.39   | 1.00   | 56.8%      |
| LLaMA   | -0.0422 | 0.1160 | -0.50   | 0.51   | 31.0%      |
| Gemma   | -0.0023 | 0.0783 | -0.20   | 0.50   | 37.1%      |

Tabella 4.1: Statistiche descrittive del CATE nel dominio RCT

Un elemento critico è la presenza di outlier estremi nei modelli LLM (ad esempio valori pari a 1.0 o  $-0.5$ ), completamente assenti in BCAUSS. Tali valori contribuiscono ad aumentare la varianza e l'errore (RMSE) senza riflettere una reale eterogeneità causale.

**Granularità delle predizioni** BCAUSS produce una distribuzione quasi continua (oltre 300 valori distinti su 321 osservazioni), mentre gli LLM mostrano una marcata discretizzazione delle predizioni. Mistral genera 37 valori distinti, LLaMA 55 e Gemma 45, con concentrazione su pochi livelli ricorrenti.

| Modello | Valori unici | Valori più frequenti   |
|---------|--------------|------------------------|
| Mistral | 37           | 0.01, 0.08, 0.02, 0.00 |
| LLaMA   | 55           | -0.15, 0.00, 0.08      |
| Gemma   | 45           | 0.00 (dominante)       |

Tabella 4.2: Granularità delle predizioni nel dominio RCT

**Interpretazione** Questi risultati suggeriscono che gli LLM non approssimano una funzione continua del CATE, ma operano su un insieme limitato di livelli discreti. In termini econometrici, ciò è coerente con una perdita di informazione sull'eterogeneità individuale.

Le correlazioni tra BCAUSS e gli LLM sono prossime allo zero:

- BCAUSS vs Mistral:  $-0.0226$
- BCAUSS vs LLaMA:  $0.0171$
- BCAUSS vs Gemma:  $\sim 0$

Questo risultato indica che gli LLM non preservano l'ordinamento relativo degli individui. In termini pratici, individui con effetti molto diversi secondo BCAUSS risultano indistinguibili nei modelli linguistici.

### 4.3.2 Dominio OBS

Nel dominio osservazionale, BCAUSS mostra un chiaro shift distribuzionale: la media del CATE passa da  $-0.0936$  a  $0.1175$ , con uno spostamento pari a  $0.2111$ , coerente con l'introduzione di bias di selezione.

Gli LLM, invece, risultano quasi insensibili al cambiamento di dominio:

- **Mistral:** media  $0.0086$ , shift  $\sim 0.0004$

- **LLaMA**: media  $-0.0682$ , shift  $\sim 0.026$
- **Gemma**: media  $0.0017$ , shift  $\sim 0.004$

| Modello | Media (OBS) | Std    | Min     | Max    | Shift  |
|---------|-------------|--------|---------|--------|--------|
| BCAUSS  | 0.1175      | 0.0372 | -0.0028 | 0.1748 | 0.2111 |
| Mistral | 0.0086      | 0.0653 | -0.21   | 1.00   | 0.0004 |
| LLaMA   | -0.0682     | 0.1855 | -1.00   | 1.00   | 0.0259 |
| Gemma   | 0.0017      | 0.2353 | -1.00   | 1.00   | 0.0040 |

Tabella 4.3: Statistiche del CATE nel dominio OBS e shift rispetto al dominio RCT

Un ulteriore elemento è la distribuzione quasi interamente positiva di BCAUSS (positive rate  $> 99\%$ ), mentre gli LLM mantengono distribuzioni incoerenti (ad esempio Gemma con solo il  $5.4\%$  di valori positivi).

**Granularità delle predizioni** La differenza nella granularità persiste anche nel dominio OBS. BCAUSS mantiene una rappresentazione quasi continua (circa 250 valori distinti, pari al  $77.9\%$ ), mentre gli LLM restano fortemente discretizzati. Gli LLM, al contrario, mantengono una struttura fortemente discretizzata:

- **Mistral**: 33 valori distinti ( $10.3\%$  delle osservazioni)
- **LLaMA**: 91 valori distinti ( $28.3\%$ )
- **Gemma**: 46 valori distinti ( $14.3\%$ )

| Modello | Valori unici (classi) | % su osservazioni | Note                      |
|---------|-----------------------|-------------------|---------------------------|
| BCAUSS  | $\sim 250$            | $77.9\%$          | quasi continuo            |
| Mistral | 33                    | $10.3\%$          | forte concentrazione      |
| LLaMA   | 91                    | $28.3\%$          | discretizzazione moderata |
| Gemma   | 46                    | $14.3\%$          | accumulo su pochi livelli |

Tabella 4.4: Granularità delle predizioni nel dominio OBS

**Interpretazione** La limitata variazione nelle distribuzioni degli LLM al variare del dominio suggerisce una ridotta sensibilità ai cambiamenti nella struttura dei dati. Questo comportamento è coerente con l'evidenza già osservata nel dominio RCT.

Nel contesto osservazionale, tali risultati indicano che i modelli linguistici potrebbero non adattarsi adeguatamente alla presenza di bias di selezione, con potenziali implicazioni per l'inferenza causale.

### 4.3.3 Analisi visiva

A supporto dell'analisi quantitativa, i grafici di densità permettono di confrontare direttamente le distribuzioni del CATE stimate da BCAUSS con quelle prodotte dai modelli LLM, distinguendo tra dominio RCT e dominio OBS.

Nel dominio RCT (pannelli sinistri delle Figure 1–3), la distribuzione stimata da BCAUSS presenta una chiara struttura bimodale, con due picchi distinti localizzati approssimativamente intorno a  $-0.15$  e  $-0.05$ . Questa configurazione evidenzia una marcata eterogeneità dell’effetto del trattamento, che tuttavia non viene riprodotta dai modelli linguistici.

Le distribuzioni generate dagli LLM mostrano infatti comportamenti profondamente diversi. Mistral concentra la maggior parte della massa di probabilità in prossimità dello zero, suggerendo una sostanziale incapacità di cogliere la presenza del picco principale osservato in BCAUSS. Gemma produce invece una distribuzione più regolare ma eccessivamente smussata e unimodale, che attenua significativamente la variabilità sottostante. Ancora più evidente è il caso di LLaMA, la cui distribuzione assume una forma fortemente discretizzata, con picchi netti e separati (intorno a  $-0.15$ ,  $0$  e  $+0.05$ ), indicando una marcata quantizzazione delle predizioni.

Nel complesso, l’analisi visiva nel dominio RCT conferma una discrepanza strutturale tra BCAUSS e i modelli LLM: mentre il primo restituisce una rappresentazione articolata e continua dell’eterogeneità del trattamento, i secondi tendono a semplificare e distorcere tale struttura, riducendone la granularità o introducendo artefatti di discretizzazione.

Queste differenze risultano ancora più rilevanti quando si passa al dominio osservazionale. Nei pannelli di destra delle Figure 1–3, infatti, le distribuzioni del CATE mostrano un’ulteriore perdita di struttura, coerente con la presenza di bias nei dati di input. In questo contesto, le stime dei modelli LLM appaiono generalmente ancora più concentrate e meno informative, accentuando la tendenza già osservata nel dominio RCT a comprimere la variabilità o a introdurre schemi artificiali. Di conseguenza, il confronto visivo suggerisce che le criticità dei modelli linguistici non solo persistono, ma tendono ad amplificarsi in presenza di dati osservazionali, dove la corretta ricostruzione dell’eterogeneità del trattamento risulta intrinsecamente più complessa.




Figura 4.1: Confronto delle densità del CATE tra BCAUSS e Mistral nei domini RCT (sinistra) e OBS (destra).

#### 4.3.4 Analisi della concordanza tramite Bland–Altman

Per analizzare in modo approfondito la relazione tra le stime prodotte da BCAUSS e quelle ottenute dai modelli LLM, sono stati utilizzati grafici di Bland–Altman. Tale metodologia consente di valutare non solo la presenza di un bias sistematico tra i metodi, ma anche la struttura dell’errore lungo l’intero dominio delle predizioni.




Figura 4.2: Confronto delle densità del CATE tra BCAUSS e Gemma nei domini RCT (sinistra) e OBS (destra).




Figura 4.3: Confronto delle densità del CATE tra BCAUSS e LLaMA nei domini RCT (sinistra) e OBS (destra). Si osserva in particolare la forte discretizzazione delle predizioni nel dominio RCT.

In ciascun grafico:

- l'asse delle ascisse rappresenta la media tra le due stime;
- l'asse delle ordinate rappresenta la differenza tra BCAUSS e LLM (BCAUSS – LLM);
- la linea centrale indica il bias medio;
- le bande tratteggiate rappresentano i limiti di concordanza.

Questa rappresentazione consente di verificare se le discrepanze tra i modelli siano distribuite in modo casuale oppure presentino strutture sistematiche, come già suggerito dall'analisi delle distribuzioni.

Una prima evidenza riguarda la coerenza del comportamento tra i due domini analizzati. In particolare:

- nel dominio OBS si osserva un bias medio positivo, indicativo di una sottostima sistematica degli LLM rispetto a BCAUSS;
- nel dominio RCT emerge un bias negativo, che segnala una tendenza alla sovrastima.

Il cambiamento di segno del bias tra i due contesti suggerisce che le differenze tra i modelli non siano riconducibili a fluttuazioni casuali, ma riflettano una dipendenza strutturale dalla natura del dataset.

L'analisi dei singoli modelli evidenzia comportamenti distinti.

**Gemma** mostra una notevole variabilità nelle stime. Nel dominio RCT, l'errore presenta un'elevata dispersione e un evidente bias proporzionale (trend decrescente dei residui): all'aumentare del valore medio della stima, la differenza diventa progressivamente più negativa, indicando che il modello tende a sovrastimare in misura sempre maggiore per valori predetti elevati. Nel dominio OBS, pur essendovi una concentrazione dei dati in un range ristretto, la presenza di outlier estremi (con differenze prossime a  $\pm 1$ ) dilata notevolmente l'ampiezza dei limiti di concordanza, denotando instabilità su specifiche istanze.

Il comportamento di **LLaMA** risulta strutturalmente anomalo. Come chiaramente visibile nel grafico del dominio RCT, le differenze non si distribuiscono in modo stocastico, ma si allineano lungo tre distinte rette parallele a pendenza negativa. Questo pattern geometrico e artificiale, riscontrabile sotto forma di segmenti e gradienti anche nel dominio OBS, suggerisce che il modello non genera stime su uno spazio continuo. Al contrario, sembra applicare regole deterministiche rigide o logiche di quantizzazione (approssimazioni a gradino), discostandosi fortemente dalla dinamica attesa per un predittore statistico naturale.

Infine, **Mistral** esibisce la distribuzione dei residui più compatta e densa attorno alla linea del bias medio, specialmente nel dominio RCT per i valori più frequenti. Ciò indica una concordanza strutturale superiore con le stime di BCAUSS per la maggior parte del campione analizzato. Tuttavia, il modello risulta vulnerabile agli estremi: in entrambi i domini si osservano isolati ma severi outlier nel quadrante in basso a destra. Questo dimostra che, sebbene molto stabile sulla casistica ordinaria, in corrispondenza di valori target elevati Mistral può generare sovrastime marcate.

Complessivamente, i grafici di Bland–Altman evidenziano come nessuno dei modelli LLM sia in grado di riprodurre fedelmente il comportamento di BCAUSS. Tuttavia, Mistral appare il modello con la distribuzione degli errori più vicina a quella attesa in presenza di discrepanze puramente casuali, mentre Gemma e LLaMA mostrano rispettivamente problemi di instabilità e di struttura artificiale delle predizioni.

Analizzando i singoli modelli, emergono comportamenti distinti ma coerenti con quanto osservato nei grafici di densità.

#### 4.3.5 Metriche di errore tra BCAUSS e modelli LLM

Per quantificare le differenze tra BCAUSS e i modelli linguistici, sono state calcolate per ciascun confronto le principali metriche di errore: MAE, RMSE e bias medio. Le tabelle seguenti riportano i risultati per entrambi i domini (RCT e OBS).

I valori quantitativi risultano coerenti con le evidenze qualitative emerse dall'analisi Bland–Altman. In particolare, il bias negativo nel dominio RCT conferma la tendenza alla sovrastima da parte dei modelli LLM, mentre i valori di RMSE riflettono la disper-




Figura 4.4: Grafici di Bland–Altman BCAUSS vs Mistral per RCT (sinistra) e OBS (destra).




Figura 4.5: Grafici di Bland–Altman BCAUSS vs Gemma per RCT (sinistra) e OBS (destra).




Figura 4.6: Grafici di Bland–Altman BCAUSS vs LLaMA per RCT (sinistra) e OBS (destra).

sione osservata nei grafici, più marcata nei modelli caratterizzati da maggiore instabilità o da artefatti strutturali.

Nel dominio RCT, tutti i modelli presentano bias negativo, confermando la tendenza alla sovrastima. Le differenze tra i modelli in termini di MAE e RMSE risultano contenute, suggerendo una capacità complessivamente simile nel riprodurre le stime di BCAUSS in

| Confronto               | MAE     | RMSE    | Bias medio |
|-------------------------|---------|---------|------------|
| BCAUSS vs Mistral (RCT) | 0.11515 | 0.15459 | -0.09973   |
| BCAUSS vs LLaMA (RCT)   | 0.10832 | 0.13085 | -0.04072   |
| BCAUSS vs Gemma (RCT)   | 0.10534 | 0.13450 | -0.09161   |

Tabella 4.5: Metriche di errore (MAE, RMSE, bias medio) per il dominio RCT

| Confronto               | MAE     | RMSE    | Bias medio |
|-------------------------|---------|---------|------------|
| BCAUSS vs Mistral (OBS) | 0.11588 | 0.13159 | 0.10938    |
| BCAUSS vs LLaMA (OBS)   | 0.17685 | 0.25095 | 0.15508    |
| BCAUSS vs Gemma (OBS)   | 0.19430 | 0.28881 | 0.09159    |

Tabella 4.6: Metriche di errore (MAE, RMSE, bias medio) per il dominio OBS

assenza di bias strutturali nel dataset.

Nel dominio OBS, invece, emerge un aumento significativo degli errori, in particolare per LLaMA e Gemma. I valori più elevati di RMSE indicano una maggiore dispersione delle differenze, coerente con la variabilità osservata nei grafici. Mistral mantiene prestazioni relativamente migliori, pur mostrando anch'esso un incremento dell'errore rispetto al contesto RCT.

Nel complesso, l'analisi quantitativa conferma che:

- il dominio OBS introduce maggiore instabilità nelle predizioni;
- le differenze tra modelli emergono con maggiore evidenza in presenza di bias;
- Mistral risulta il modello più robusto, mentre LLaMA e Gemma mostrano rispettivamente problemi di struttura e di dispersione.

### 4.3.6 Correlazione lineare e di rango

Per valutare in modo più approfondito la relazione tra le stime di BCAUSS e quelle dei modelli LLM, sono state considerate due misure complementari:

- **Correlazione di Pearson**, che misura la dipendenza lineare tra le due variabili;
- **Correlazione di Spearman**, che misura la coerenza nell'ordinamento relativo (ranking) degli individui.

Questa distinzione è fondamentale nel contesto del CATE: mentre Pearson valuta l'allineamento numerico delle stime, Spearman è particolarmente rilevante per verificare se i modelli preservano l'eterogeneità relativa tra individui.

**Dominio RCT** Nel dominio sperimentale, entrambe le metriche risultano sistematicamente prossime allo zero:

- **Mistral**: Pearson  $-0.0226$ , Spearman  $-0.0447$
- **LLaMA**: Pearson  $0.0171$ , Spearman  $0.0144$
- **Gemma**: Pearson  $\sim 0$ , Spearman  $-0.0088$

Questi valori indicano l'assenza sia di relazione lineare sia di coerenza nel ranking. In particolare:

- la correlazione di Pearson nulla implica che le variazioni nelle stime di BCAUSS non sono spiegate dalle predizioni degli LLM;
- la correlazione di Spearman nulla indica che gli LLM non preservano nemmeno l'ordinamento relativo degli individui.

Questo risultato è particolarmente critico: anche nel contesto RCT, i modelli linguistici non riescono a identificare quali individui abbiano effetti maggiori o minori, fallendo quindi l'obiettivo principale della stima del CATE.

**Dominio OBS** Nel dominio osservazionale, si osserva un comportamento leggermente diverso ma comunque problematico:

- **Mistral**: Pearson 0.1250, Spearman 0.0742
- **LLaMA**: Pearson  $-0.0977$ , Spearman  $-0.0248$
- **Gemma**: Pearson  $-0.1086$ , Spearman  $-0.1117$

In questo caso:

- Mistral mostra una correlazione debolmente positiva, suggerendo una minima capacità di cogliere la direzione generale delle variazioni;
- LLaMA e Gemma presentano correlazioni negative o nulle, indicando una relazione inversa o assente rispetto alle stime di BCAUSS.

Tuttavia, anche il valore più alto (Pearson  $\sim 0.12$  per Mistral) rimane estremamente basso e non statisticamente rilevante in termini pratici. La correlazione di Spearman, anch'essa molto ridotta, conferma che il ranking degli individui non viene preservato.

Nel complesso, l'introduzione del bias non migliora la capacità degli LLM di allinearsi a BCAUSS, ma anzi evidenzia ulteriormente la loro instabilità.

## 4.4 Analisi complessiva e conclusioni

L'insieme dei risultati evidenzia una discrepanza strutturale tra approcci causali e modelli linguistici.

**Capacità di modellare l'eterogeneità** BCAUSS mostra una rappresentazione coerente e continua del CATE, preservando sia la variabilità individuale sia l'ordinamento relativo tra individui. Questo è confermato da:

- distribuzioni strutturate e interpretabili;
- elevata granularità delle predizioni;
- coerenza tra analisi numeriche e visive.

Gli LLM, al contrario:

- producono distribuzioni distorte o eccessivamente smussate;
- mostrano forte discretizzazione (quantizzazione);
- non preservano il ranking (Spearman  $\sim 0$ ).

**Allineamento con il modello causale** Le correlazioni di Pearson e Spearman forniscono un risultato chiave: non esiste alcuna relazione significativa tra le stime di BCAUSS e quelle degli LLM. Questo implica che:

- gli LLM non approssimano nemmeno qualitativamente la funzione del CATE;
- le loro predizioni non sono utilizzabili per inferenze causali individuali.

**Sensibilità al cambio di dominio** BCAUSS reagisce in modo coerente all'introduzione di bias (shift  $\sim 0.21$ ), mentre gli LLM mostrano una quasi totale insensibilità (shift prossimo a zero). Questo indica che:

- BCAUSS cattura la struttura causale sottostante;
- gli LLM operano in modo sostanzialmente indipendente dalla distribuzione dei dati.

**Errore e stabilità** Le metriche di errore confermano il quadro generale:

- nel dominio RCT, gli errori sono già elevati nonostante l'assenza di bias;
- nel dominio OBS, l'errore aumenta significativamente, in particolare per LLaMA e Gemma (RMSE fino a 0.289);
- Mistral risulta il modello relativamente più stabile, ma comunque inadeguato.

**Conclusione finale** Nel complesso, i risultati mostrano che i modelli LLM non sono in grado di stimare il CATE in modo affidabile. Le principali criticità osservate sono:

- assenza di correlazione (lineare e di rango) con il modello causale;
- perdita di granularità e discretizzazione delle predizioni;
- incapacità di preservare l'eterogeneità individuale;
- insensibilità al cambiamento di dominio;
- presenza di outlier e instabilità nelle stime.

Questi elementi suggeriscono che, in assenza di una modellazione esplicitamente causale o di un meccanismo di calibrazione, i Large Language Models non rappresentano strumenti adeguati per la stima del CATE, in particolare in contesti caratterizzati da eterogeneità individuale e bias di selezione.

Al contrario, approcci causali come BCAUSS risultano più coerenti con gli obiettivi inferenziali, fornendo stime interpretabili, stabili e sensibili alla struttura dei dati.

---

## REFERENCES

- [1] Alistair E. W. Johnson et al. «MIMIC-IV, a freely accessible electronic health record dataset». en. In: *Scientific Data* 10.1 (gen. 2023), p. 1. ISSN: 2052-4463. DOI: [10.1038/s41597-022-01899-x](https://doi.org/10.1038/s41597-022-01899-x).
- [2] Scott M. Hammer et al. «A Trial Comparing Nucleoside Monotherapy with Combination Therapy in HIV-Infected Adults with CD4 Cell Counts from 200 to 500 per Cubic Millimeter». en. In: *New England Journal of Medicine* 335.15 (ott. 1996), pp. 1081–1090. ISSN: 0028-4793, 1533-4406. DOI: [10.1056/NEJM199610103351501](https://doi.org/10.1056/NEJM199610103351501).
- [3] Manu L.N.G. Malbrain, Niels Van Regenmortel e Radosław Owczuk. «It is time to consider the four D's of fluid management». In: *Anestezjologia Intensywna Terapia* 47.J (dic. 2015), pp. 1–5. ISSN: 1731-2531, 1642-5758. DOI: [10.5603/AIT.a2015.0070](https://doi.org/10.5603/AIT.a2015.0070).
- [4] Alwin Tilanus e Wilmer Villamil. «Fever in Sepsis Revisited: Is a Little Heat What We Need?» en. In: *Open Forum Infectious Diseases* 12.10 (2025), ofaf608. ISSN: 2328-8957. DOI: [10.1093/ofid/ofaf608](https://doi.org/10.1093/ofid/ofaf608).
- [5] Liping Zhou et al. «Loop Diuretics Are Associated with Increased Risk of Hospital-Acquired Acute Kidney Injury in Adult Patients: A Retrospective Study». en. In: *Journal of Clinical Medicine* 11.13 (2022), p. 3665. ISSN: 2077-0383. DOI: [10.3390/jcm11133665](https://doi.org/10.3390/jcm11133665).
- [6] Yingxin Wang et al. «Prognostic impact of early versus delayed loop diuretic administration in sepsis: a propensity score-matched analysis using the MIMIC-IV database». In: *Translational Andrology and Urology* 14.3 (mar. 2025), pp. 779–790. ISSN: 22234683, 22234691. DOI: [10.21037/tau-24-620](https://doi.org/10.21037/tau-24-620).